UNIVERSIDAD EAFIT®



APRENDIZAJE POR REFUERZO

APRENDER A DECIDIR CON RECOMPENSAS

CEYNI PAOLA BELTRÁN HOYOS
CARLOS GUILLERMO ZÚÑIGA MÉNDEZ

APRENDIZAJE AUTOMÁTICO · 2026-2


p
Bart v. Cupcakes
poorguy234
Watch on YouTube

DE PREDECIR A DECIDIR



La sesión 3 predijo el tráfico; hoy un agente decide qué hacer con él.

Sesión 3: predecir

$$\hat{y}_{t+h} = f(X_t)$$

¿Cuánto tráfico habrá en una hora?

Hoy: decidir

$$A_t \sim \pi(\cdot \mid S_t)$$

¿Qué hace el semáforo ahora?

De la analítica predictiva a la prescriptiva

Silver et al. (2016), Mastering the game of Go with deep neural networks and tree search.
Ouyang et al. (2022), Training language models to follow instructions with human feedback.

QUÉ CAMBIA FRENTE AL APRENDIZAJE SUPERVISADO

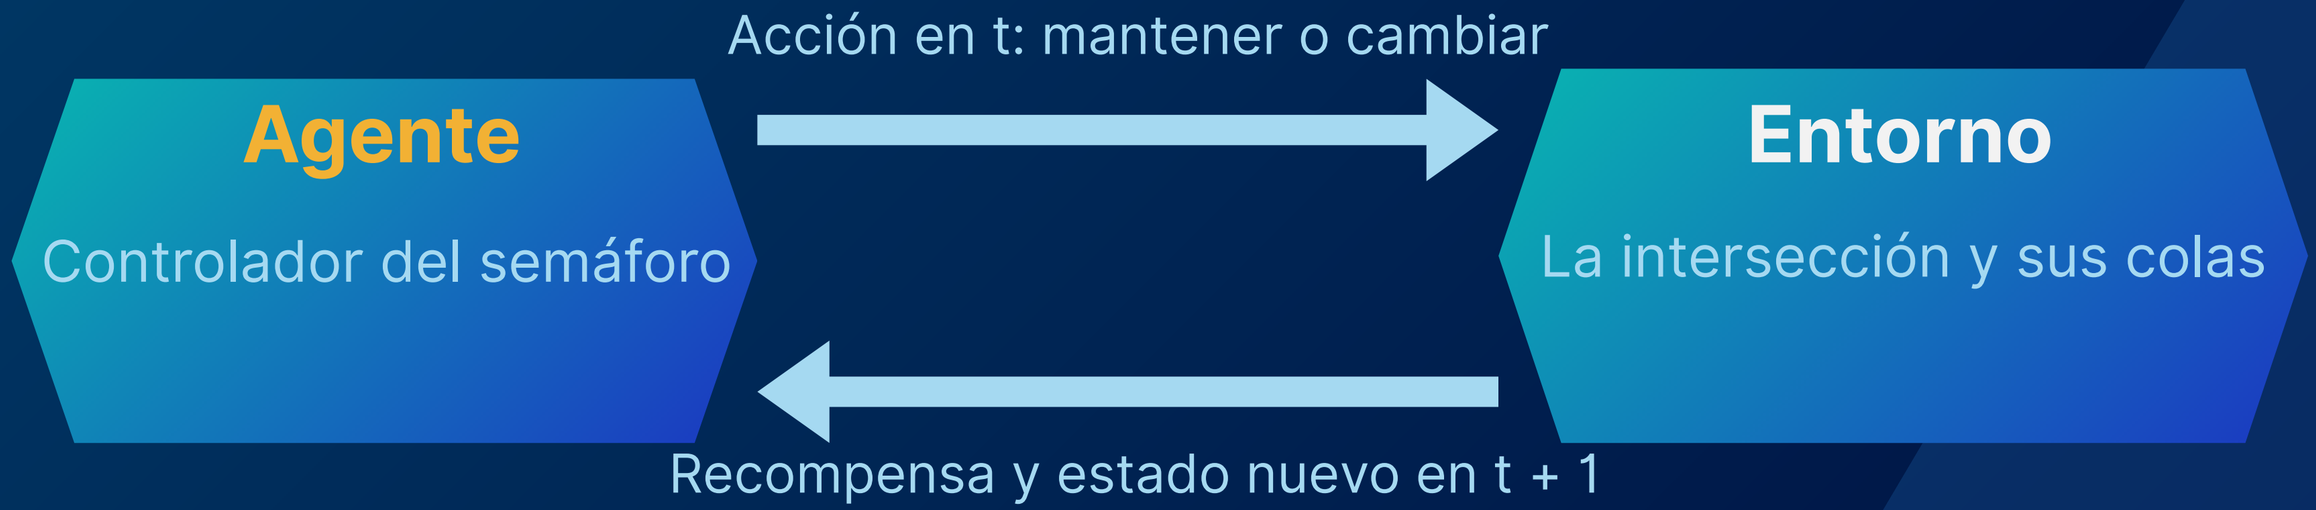
Nadie le da la respuesta correcta al agente, y sus decisiones cambian sus datos

	Supervisado	Refuerzo
Una fila es	(x, y)	(s, a, r, s′)
Qué recibe	La respuesta correcta	Una recompensa que califica
Cuándo llega	De inmediato	Puede llegar muchos pasos después
Los datos	Son fijos	Dependen de lo que el agente hace

Duda et al. (2001), Pattern classification, cap. 1 · Bishop (2006), Pattern recognition and machine learning, p. 3.
Murphy (2012), Machine learning: A probabilistic perspective, p. 2 · Goodfellow et al. (2016), Deep learning, p. 106.

EL CICLO AGENTE-ENTORNO

En cada paso: estado, acción, recompensa y estado nuevo



$$\text{MDP} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

$$P(S_{t+1} = s' \mid S_t, A_t) = P(S_{t+1} = s' \mid S_0, A_0, \ldots, S_t, A_t)$$

Estado: colas norte-sur y oriente-occidente, y la fase
Acciones: mantener o cambiar
Recompensa: menos los carros en cola

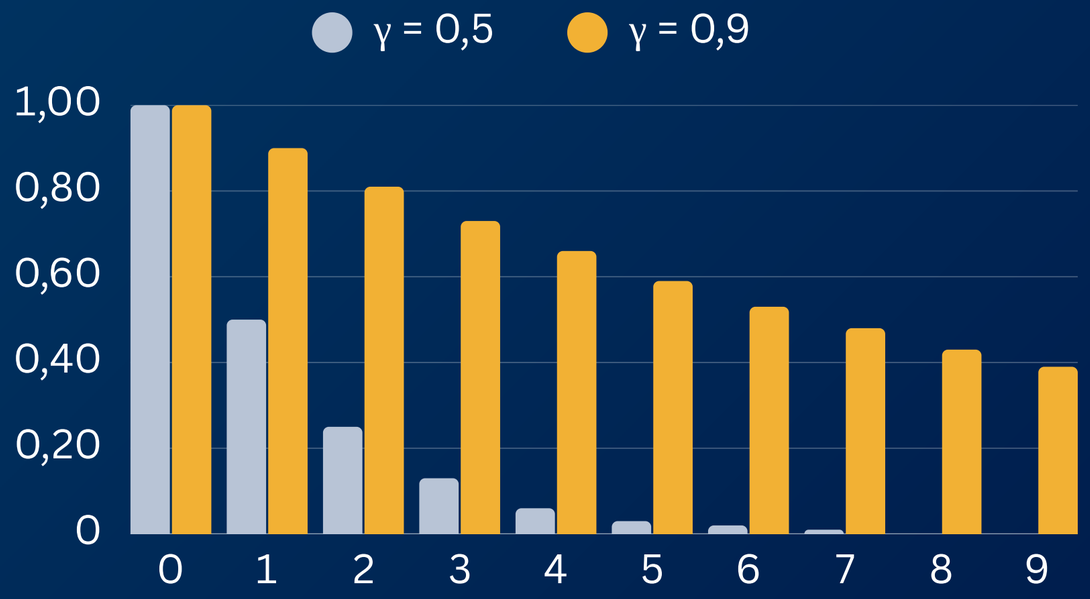
Sutton y Barto (2018), Reinforcement learning: An introduction, cap. 3.

RETORNO Y FACTOR DE DESCUENTO

Gamma decide cuánto pesa el futuro en la decisión de hoy

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

Peso de una recompensa que llega k pasos después



$$\text{horizonte efectivo} \approx \frac{1}{1-\gamma}$$

γ = 0,9 → unos 10 pasos

γ = 0,99 → unos 100 pasos

Sesión 3: h fija a qué distancia predecir. Aquí, γ fija cuánto pesa el futuro.

Sutton y Barto (2018), Reinforcement learning: An introduction, cap. 3.

POLÍTICA Y FUNCIONES DE VALOR

La política es lo que se aprende; Q mide qué tan buena es cada acción

$$\pi(a \mid s) = P(A_t = a \mid S_t = s)$$

$$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$$

$$q_\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$$

Sesión 1: el threshold era una política que fijábamos nosotros. Aquí la política se aprende

Estado	Mantener	Cambiar
N-S 2, O-E 7, verde N-S	?	?
N-S 6, O-E 1, verde N-S	?	?
N-S 0, O-E 4, verde O-E	?	?

Se llena en el código de la segunda parte

Sutton y Barto (2018), Reinforcement learning: An introduction, cap. 3.

LA ECUACIÓN DE BELLMAN

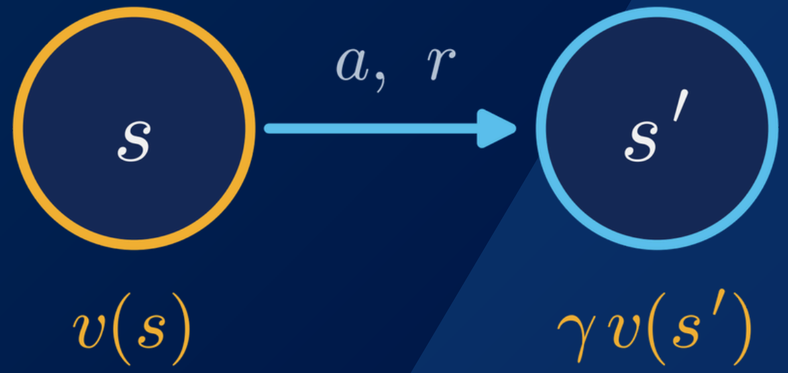
El valor de hoy es la recompensa más el valor descontado de lo que sigue

Para una política π

$$v_\pi(s) = \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \, v_\pi(s') \right]$$

Óptima

$$q_*(s, a) = \mathbb{E}\Big[\underbrace{R_{t+1}}_{\text{ahora}} + \underbrace{\gamma \max_{a'} q_*(S_{t+1}, a')}_{\text{lo que sigue, descontado}} \mid S_t = s, A_t = a \Big]$$



$$\pi_*(s) = \arg\max_a q_*(s, a)$$

Con modelo: programación dinámica
Sin modelo: aprender de muestras

Bellman (1957), Dynamic programming · Sutton y Barto (2018), Reinforcement learning: An introduction, cap. 3.

Q-LEARNING

Cada paso corrige una celda de la tabla con el error de diferencia temporal

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \Big[\underbrace{R_{t+1} + \gamma \max_a Q(S_{t+1}, a)}_{\text{objetivo}} - Q(S_t, A_t) \Big]$$

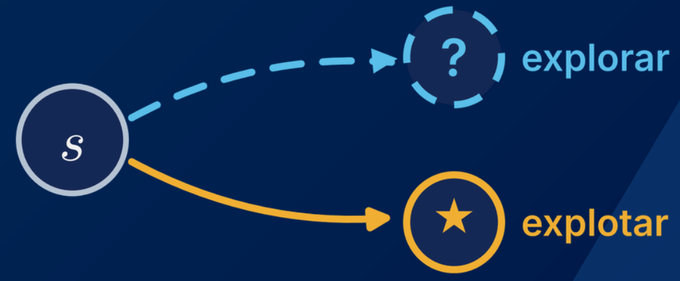
Error de diferencia temporal = observado − predicho
El observado lo arma el propio modelo (bootstrapping, distinto del bootstrap de remuestreo)

Ejemplo en el semáforo: Q(s, mantener) = −4, r = −3, γ = 0,9, mejor Q del estado nuevo = −2, α = 0,1
Objetivo: −3 + 0,9 × (−2) = **−4,8**
Error: −4,8 − (−4) = −0,8
Nuevo Q: −4 + 0,1 × (−0,8) = −4,08

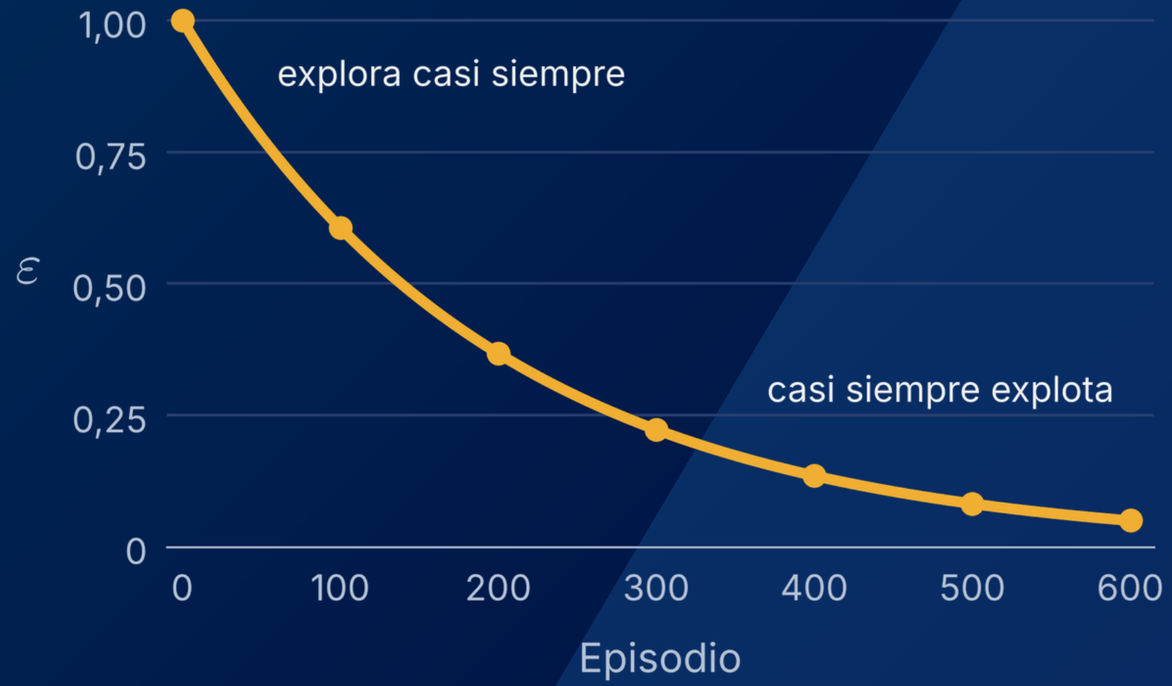
Watkins (1989), Learning from delayed rewards · Watkins y Dayan (1992), Q-learning.

EXPLORAR O EXPLOTAR

Sin explorar, el agente nunca sabe si había una acción mejor



$$A_t = \begin{cases} \arg\max_a Q(S_t, a) & \text{con probabilidad } 1-\varepsilon \\ \text{una acción al azar} & \text{con probabilidad } \varepsilon \end{cases}$$



Sesión 2 · UCB = μ + κσ: premia la media alta y la incertidumbre alta

Sesión 4 · bandits contextuales para recomendar noticias (Yahoo, 2010)

Li et al. (2010), A contextual-bandit approach to personalized news article recommendation.

CÓMO SE EVALÚA UN AGENTE

Lo mismo que se exige a cualquier modelo

- ✓ Política aleatoria y semáforo de tiempo fijo como baselines
- ✓ Curva de retorno por episodio, con varias semillas y su dispersión
- ✓ Evaluación final sin exploración, en episodios aparte
- ✓ Recompensa revisada como se revisa una métrica

¿Le gana este agente a un semáforo de tiempo fijo?

Henderson et al. (2018), Deep reinforcement learning that matters.

DESARROLLEMOS

La intersección simulada.

Este modelo busca aprender a controlar un semáforo para reducir el tiempo de espera del tráfico.

Representa dos direcciones:

- N-S: norte-sur.
- O-E: oriente-occidente.

En cada momento, una de las direcciones tiene luz verde. El agente observa cuántos carros esperan en cada cola y decide entre dos acciones:

1. Mantener la fase actual.
2. Cambiar a la otra fase.

El modelo resume la situación en un estado:

$$[S_t = (\text{cola N-S},\ \text{cola O-E},\ \text{fase verde})]$$

DESARROLLEMOS

La intersección simulada.

La métrica clave es el “reward” o recompensa, que se calcula de manera:

- Penaliza la cantidad de carros esperando.
- Penaliza cambiar de fase (estado) demasiadas veces seguidas.

$$R_{t+1} = -\left(q_{NS,t+1} + q_{OE,t+1}\right) - 0.5[A_t = \text{CAMBIAR}]$$

Nota: Los valores salen negativos.
Un valor más cercano a 0 significa mejor desempeño; un valor más negativo significa que hay más demora y más cola.

DESARROLLEMOS

¿Le gana este agente a un semáforo de tiempo fijo?

- Q-learning:
  - El agente recibe una recompensa positiva si logra disminuir las filas de autos y una penalización (recompensa negativa) si se forman filas muy largas.
  - Con base en prueba y error, actualiza constantemente estos valores hasta descubrir qué decisiones controlan mejor el tráfico.
- Proceso de aprendizaje:
  - Curva de aprendizaje.
  - Epsilon.

DESARROLLEMOS

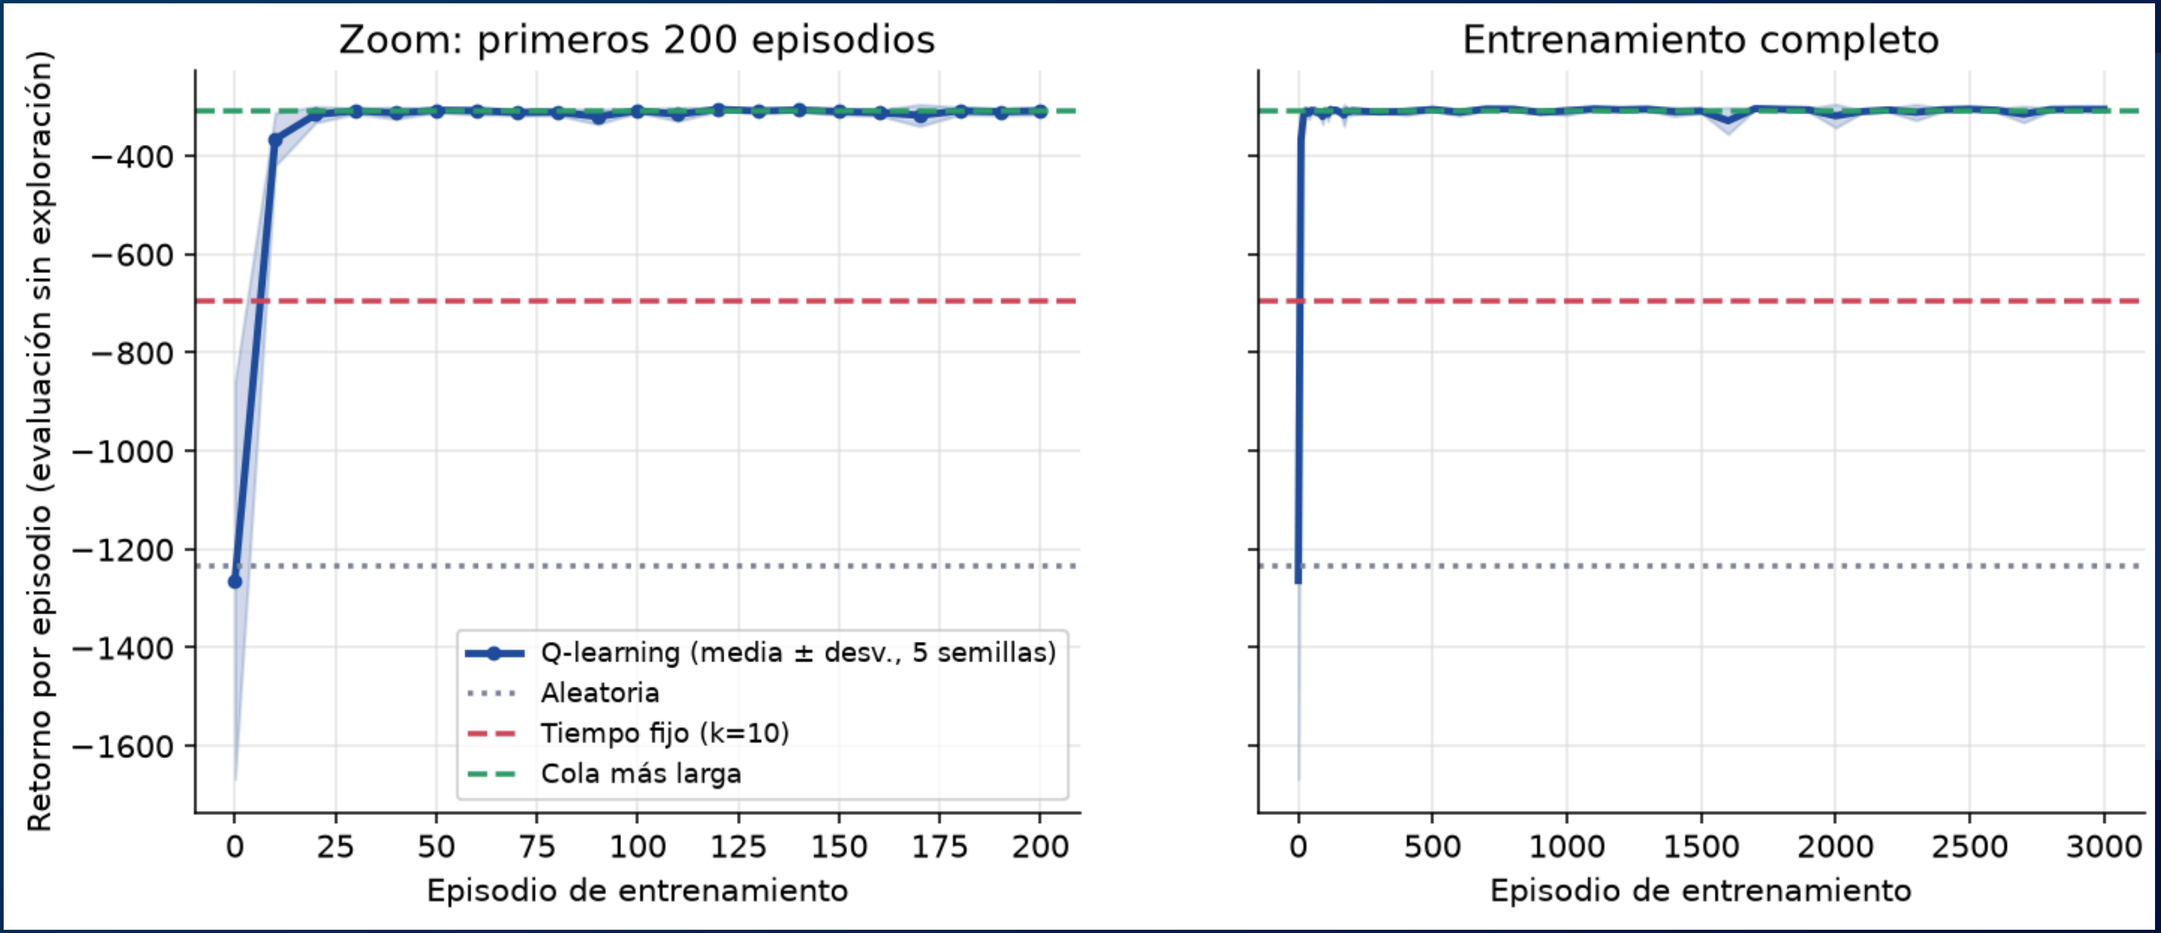
Proyecto práctico

```
[1/5] Entrenando Q-learning: 5 semillas x 3000 episodios
   semilla 0: retorno de evaluación final = -302.9
   semilla 1: retorno de evaluación final = -307.9
   semilla 2: retorno de evaluación final = -303.4
   semilla 3: retorno de evaluación final = -309.6
   semilla 4: retorno de evaluación final = -304.6
[2/5] Evaluación final (sin exploración, episodios aparte)
         Política  Retorno medio  Espera media (carros en cola)  Desv. entre episodios  Carros perdidos
         Aleatoria       -1234.76                           5.92                   1.03             9.22
Tiempo fijo (k=10)        -696.14                           3.43                   0.36             0.17
 Tiempo fijo (k=5)        -499.83                           2.40                   0.23             0.00
    Cola más larga        -308.16                           1.41                   0.15             0.00
        Q-learning        -300.94                           1.38                   0.01             0.00
```

```
   Tabla Q (media entre semillas): 3 estados de la diapositiva 6 + 1 extra:
                  Estado  Q(mantener)  Q(cambiar) Mejor acción
N-S 2, O-E 7, verde N-S        -58.0       -61.5     mantener
N-S 6, O-E 1, verde N-S        -42.5       -59.9     mantener
N-S 0, O-E 4, verde O-E        -31.1       -43.6     mantener
N-S 0, O-E 7, verde N-S        -58.6       -50.1      cambiar
```

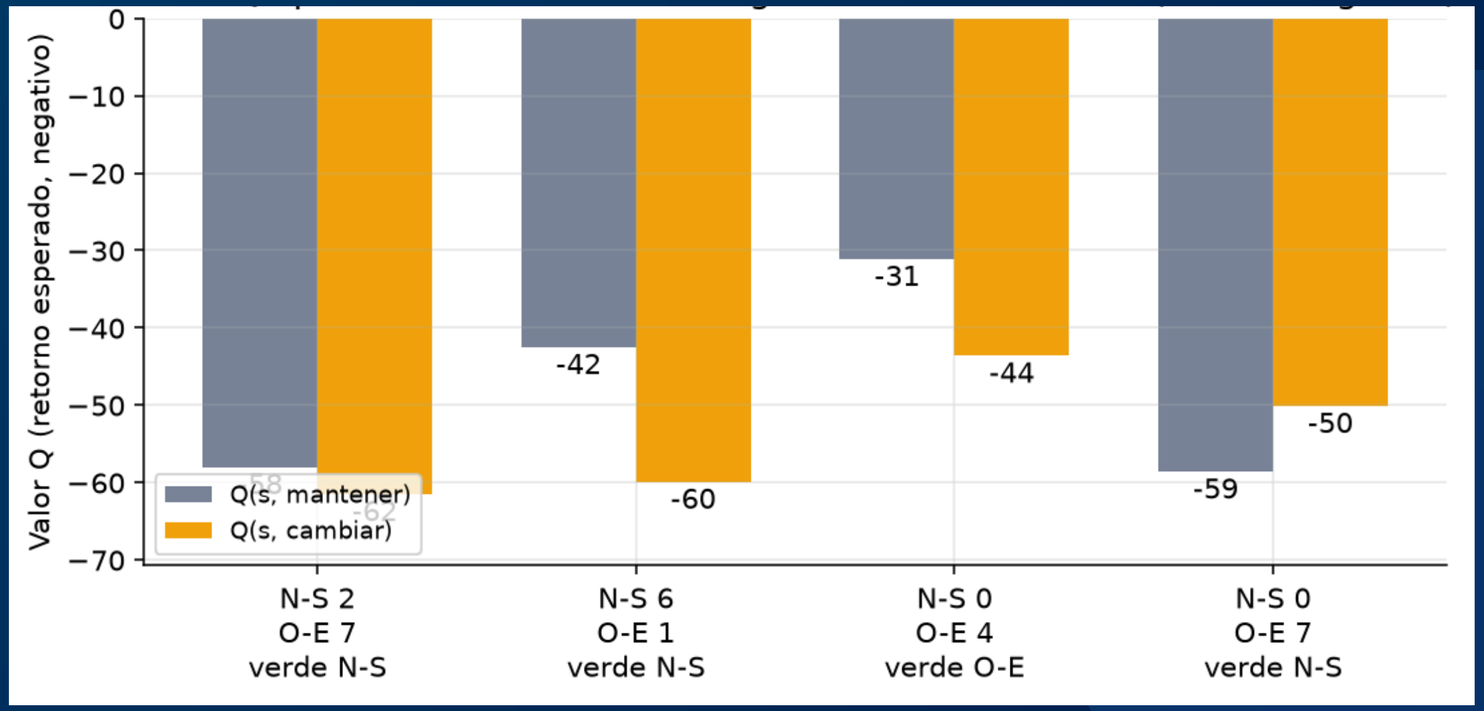
DESARROLLEMOS

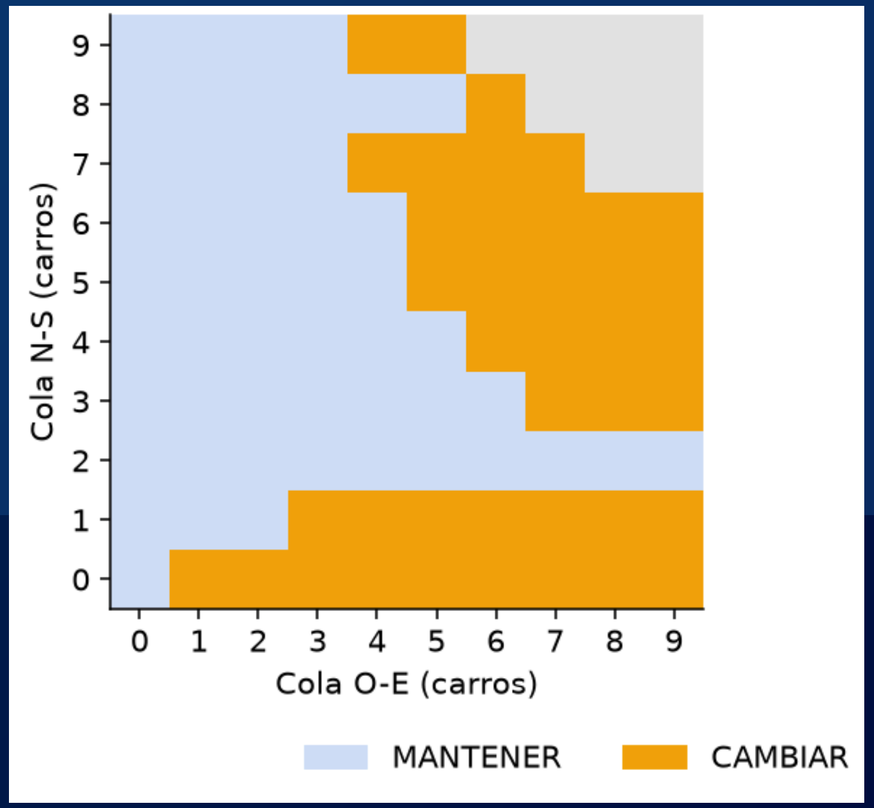
Aprendizaje por episodios y completo



DESARROLLEMOS

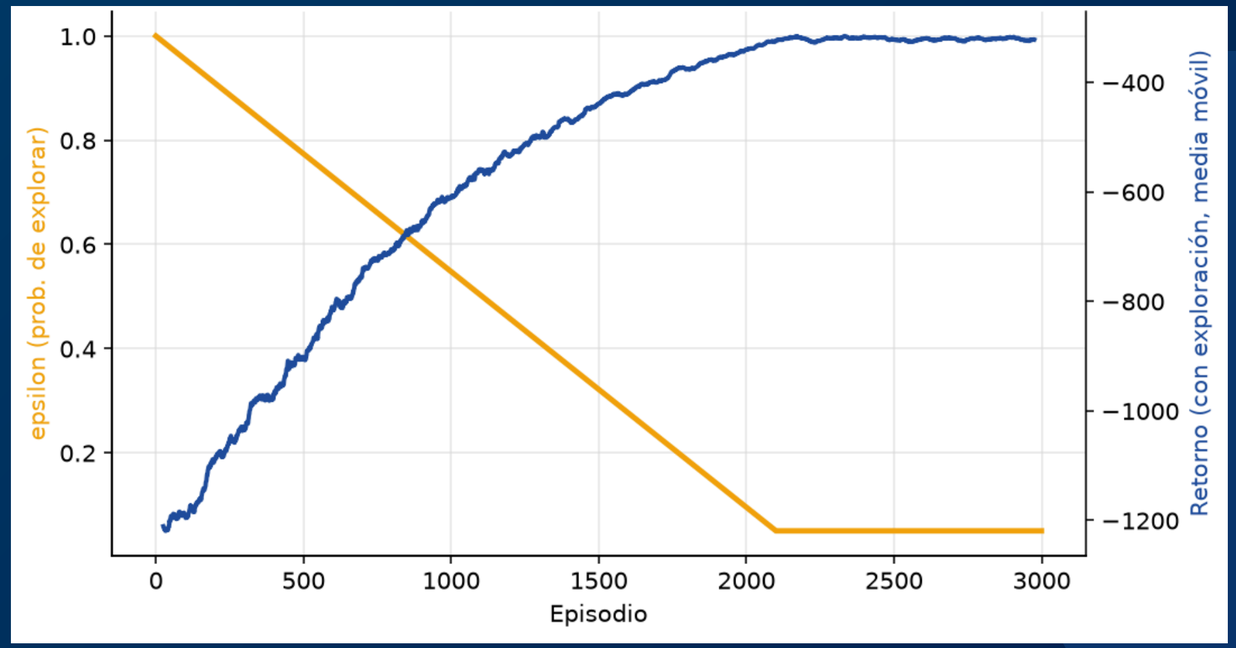
Recompensa o aprendizaje

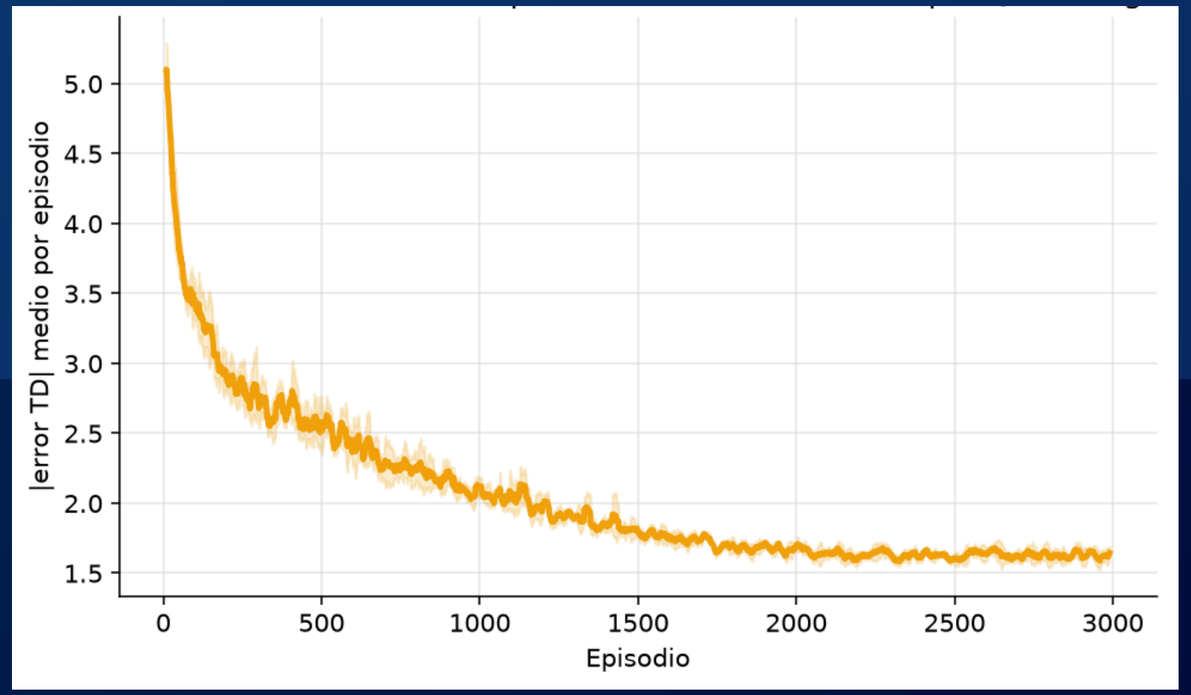




DESARROLLEMOS

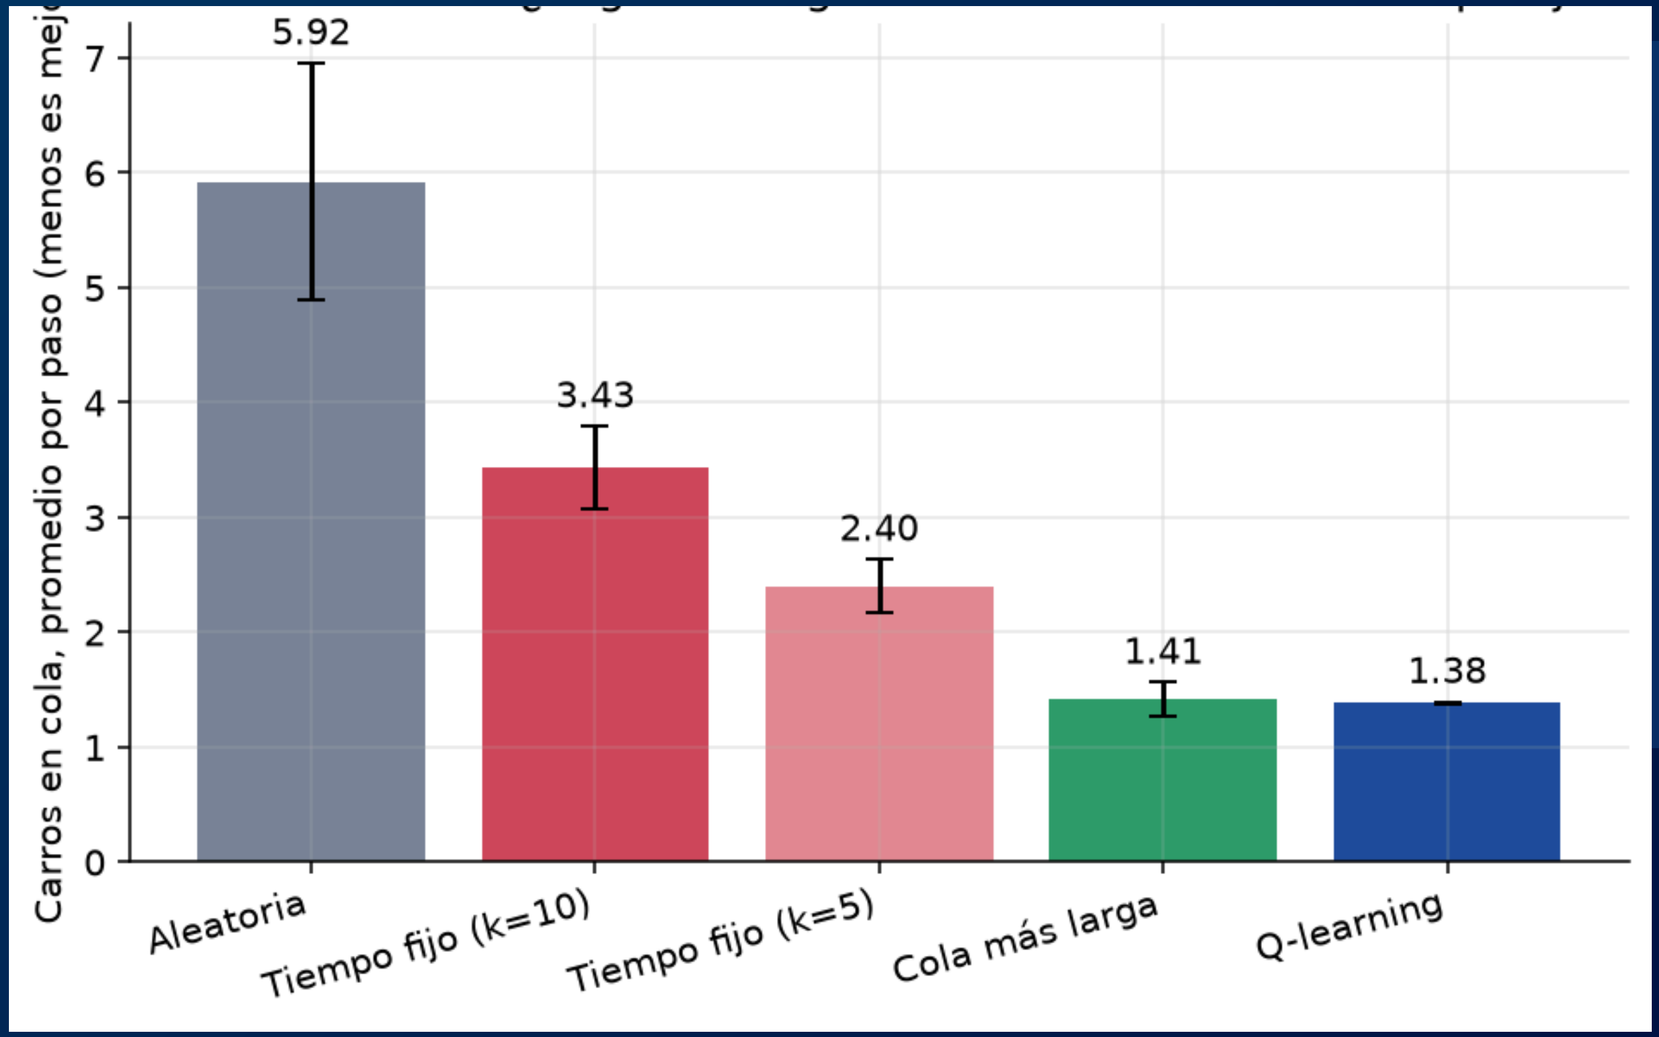
Explorar o explotar y error diferencial temporal





DESARROLLEMOS

¿Le gana el agente a un semáforo de tiempo fijo?



PARÁMETROS DE RIESGO.

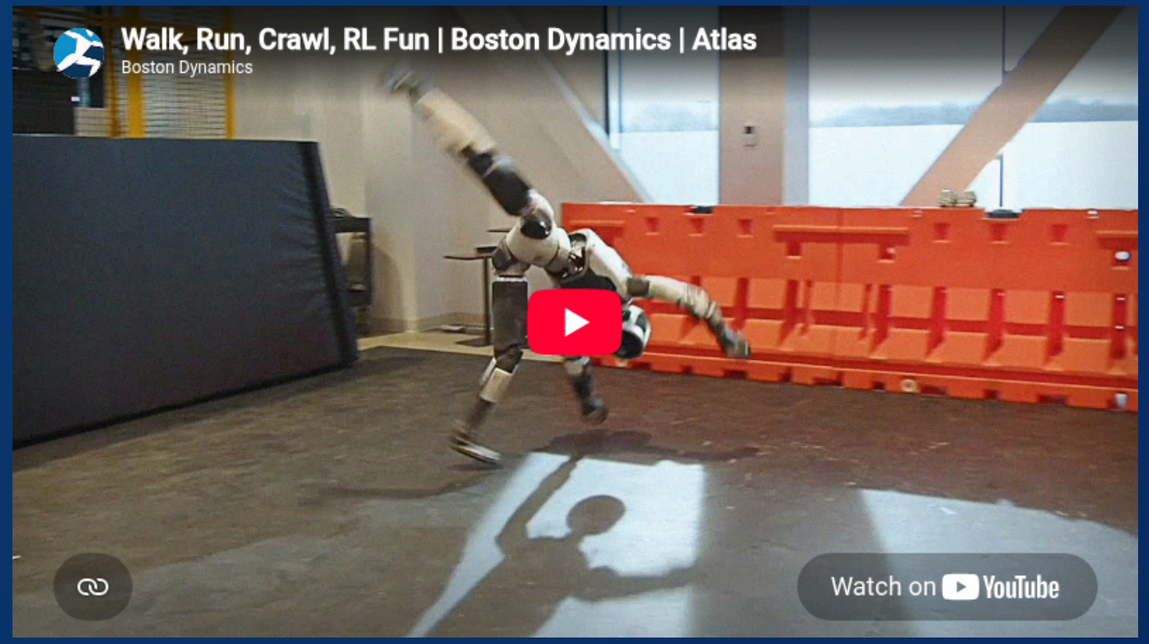
¿QUÉ TAN ÓPTIMO ES?

Categoría de Riesgo	Q-learning (Aprendizaje por Refuerzo)	Cola más larga (Heurística)
Complejidad y Estabilidad	**Alto:** Requiere un proceso de entrenamiento previo y ajuste de hiperparámetros	**Bajo:** Es una regla estática basada en lógica directa (dar verde al carril con más autos).
Adaptabilidad al Entorno	**Muy Alta:** Aprende a anticipar patrones y secuencias del tráfico a lo largo del tiempo.	**Media-Baja:** Es estrictamente reactiva; solo responde al estado del tráfico en el instante actual
Sensibilidad a Cambios Inesperados	**Media:** Si el tráfico cambia radicalmente respecto a lo aprendido durante el entrenamiento.	**Alta:** Al ser una regla fija, maneja con naturalidad cualquier volumen repentino de tráfico

MODELOS PRÁCTICOS

Ejemplos.





MJLAB (MUJOCO LAB)

BOSTON DYNAMICS

UNIVERSIDAD EAFIT®



GRACIAS

¿Preguntas?



CEYNI PAOLA BELTRÁN HOYOS
CARLOS GUILLERMO ZÚÑIGA MÉNDEZ

APRENDIZAJE AUTOMÁTICO · 2026-2