APRENDIZAJE AUTOMÁTICO · MCDA 2026-2 · UNIVERSIDAD EAFIT

Explainable AI

¿Por qué el modelo dice que esta máquina va a fallar?

[Tomás Guzmán] · [Alejandro Jiménez]

Profesor: Andrés Vásquez Restrepo · Octubre de 2026

MOTIVACIÓN

Un modelo que acierta no siempre se puede usar

EL MODELO DICE

«Esta máquina tiene 96 % de probabilidad de fallar.»

EL INGENIERO PREGUNTA

«¿Y qué reviso: la herramienta, la refrigeración o la carga?»

Actuar

Convertir la alerta en una acción concreta.

Confiar

Saber si el modelo razona con sentido.

Depurar

Detectar si aprendió algo incorrecto.

Rendir cuentas

Justificar decisiones ante clientes y reguladores.

FUNDAMENTOS

Tres preguntas ordenan los métodos de XAI

¿Cuándo se explica?

Intrínseca: el modelo ya es legible.
Post-hoc: se explica después de entrenar.

¿Qué alcance tiene?

Global: el modelo en general.
Local: una predicción concreta.

¿Depende del modelo?

Agnóstico: sirve para cualquiera.
Específico: usa su estructura interna.

LOS CUATRO MÉTODOS DE HOY (TODOS POST-HOC)

Método	Alcance	Idea en una frase
Permutación	Global	Desordeno una variable y miro cuánto empeora el modelo
PDP / ICE	Global y local	Muevo una variable y miro cómo cambia la predicción
SHAP	Local y global	Reparto la predicción entre las variables de forma justa
LIME	Local	Ajusto un modelo lineal sencillo alrededor de un caso

FUNDAMENTOS

Dos métodos globales que sirven para cualquier modelo

Importancia por permutación

Si una variable importa, romperla debe empeorar el modelo.

1. Medir el desempeño del modelo.
2. Barajar los valores de una columna.
3. Volver a medir: la caída es su importancia.

Dice cuánto importa una variable, no en qué dirección ni desde qué valor.

PDP e ICE

Mover una sola variable y ver cómo cambia la predicción.

- **ICE:** una curva por cada máquina.
- **PDP:** el promedio de todas las curvas.
- Curvas ICE muy distintas indican interacciones.

Puede crear combinaciones de valores que no existen en la realidad.

FUNDAMENTOS

SHAP reparte la predicción como un premio

Teoría de juegos	En nuestro modelo
El juego	Hacer una predicción
Los jugadores	Las variables
El premio	Predicción menos el promedio

$$\phi(j) = \Sigma\, w(S) \cdot [\, v(S + j) - v(S) \,]$$

El aporte de la variable j es su aporte marginal promediado sobre todas las coaliciones S de las demás variables.

EL ÚNICO REPARTO QUE CUMPLE CUATRO PROPIEDADES

Eficiencia
Los aportes suman exactamente la predicción.

Simetría
Quien aporta lo mismo recibe lo mismo.

Jugador nulo
Quien no cambia nada recibe cero.

Aditividad
La explicación de una suma es la suma de las explicaciones.

Lo comprobamos: programamos la fórmula a mano (64 coaliciones) y coincide con la librería hasta el sexto decimal.

Fuente: Shapley (1953); Lundberg y Lee (2017)

FUNDAMENTOS

LIME ajusta un modelo sencillo alrededor de un caso

El procedimiento

1. Tomar la máquina que se quiere explicar.
2. Crear miles de máquinas ficticias parecidas.
3. Pedir la predicción de la caja negra para cada una.
4. Dar más peso a las más cercanas a la original.
5. Ajustar una regresión lineal: sus pesos son la explicación.

FRENTE A SHAP

	SHAP	LIME
Fundamento	Teoría de juegos	Aproximación lineal local
Garantía	Suma exacta de la predicción	Ninguna
Estabilidad	Exacto en árboles	Depende del muestreo
Datos	Sobre todo tabulares	Tablas, texto e imágenes

Fuente: Ribeiro, Singh y Guestrin (2016)

EJEMPLO EN PYTHON

El caso: predecir fallas en una máquina de mecanizado

10.000
procesos de mecanizado registrados

3,39 %
terminan en falla (339 casos)

6
variables de proceso que ve el modelo

5
tipos de falla, ocultos al modelo

Variables: calidad del producto, temperatura del aire, temperatura del proceso, velocidad de giro, torque y desgaste de la herramienta.

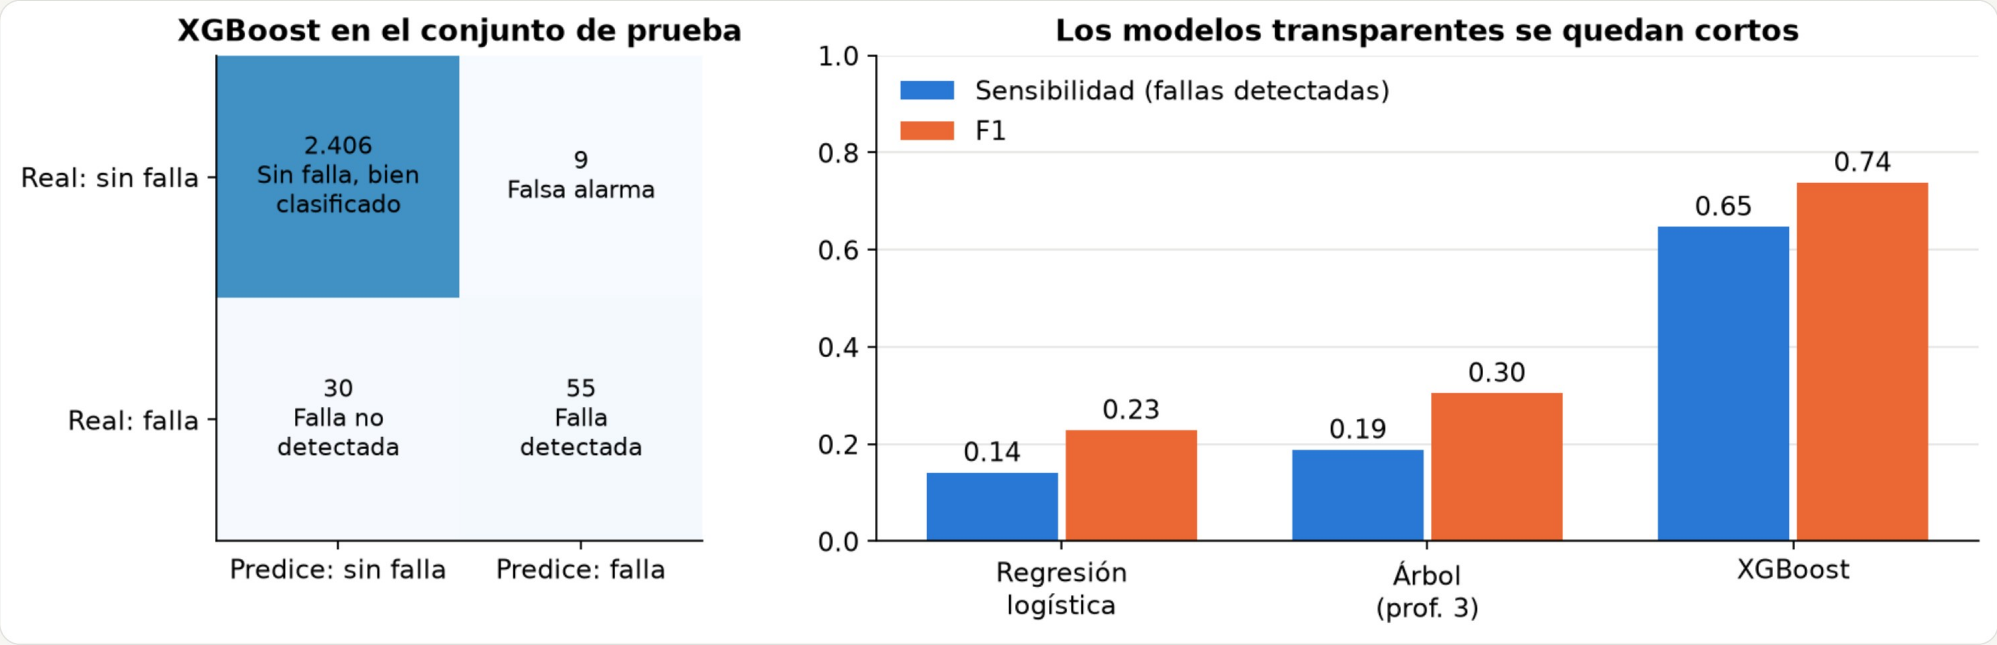
LO QUE HACE ESPECIAL A ESTE DATASET

Las fallas se generaron con reglas físicas documentadas. Esas reglas son la hoja de respuestas para comprobar si las explicaciones dicen la verdad.

Fuente: AI4I 2020 Predictive Maintenance Dataset, UCI (Matzka, 2020)

EJEMPLO EN PYTHON

Los modelos transparentes no alcanzan; XGBoost sí



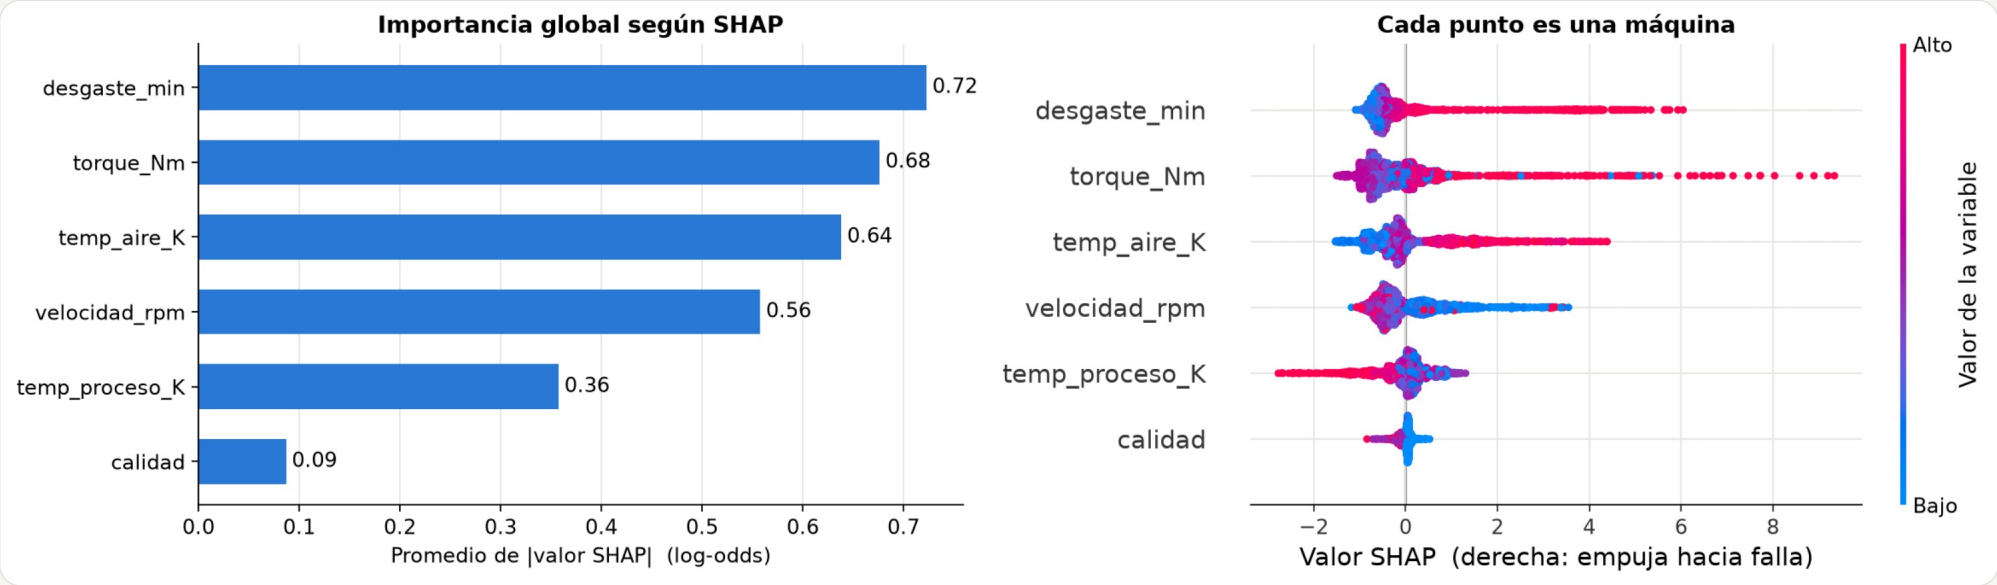
Fallas detectadas en la prueba (85 en total): regresión logística 12, árbol pequeño 16, XGBoost 55.

El costo: XGBoost son 300 árboles y 3.463 reglas de decisión. Nadie puede leer eso.

Conjunto de prueba: 2.500 procesos que el modelo no vio al entrenar

EJEMPLO EN PYTHON

La vista global: qué aprendió el modelo



Posición: a la derecha, la variable empuja hacia «falla».

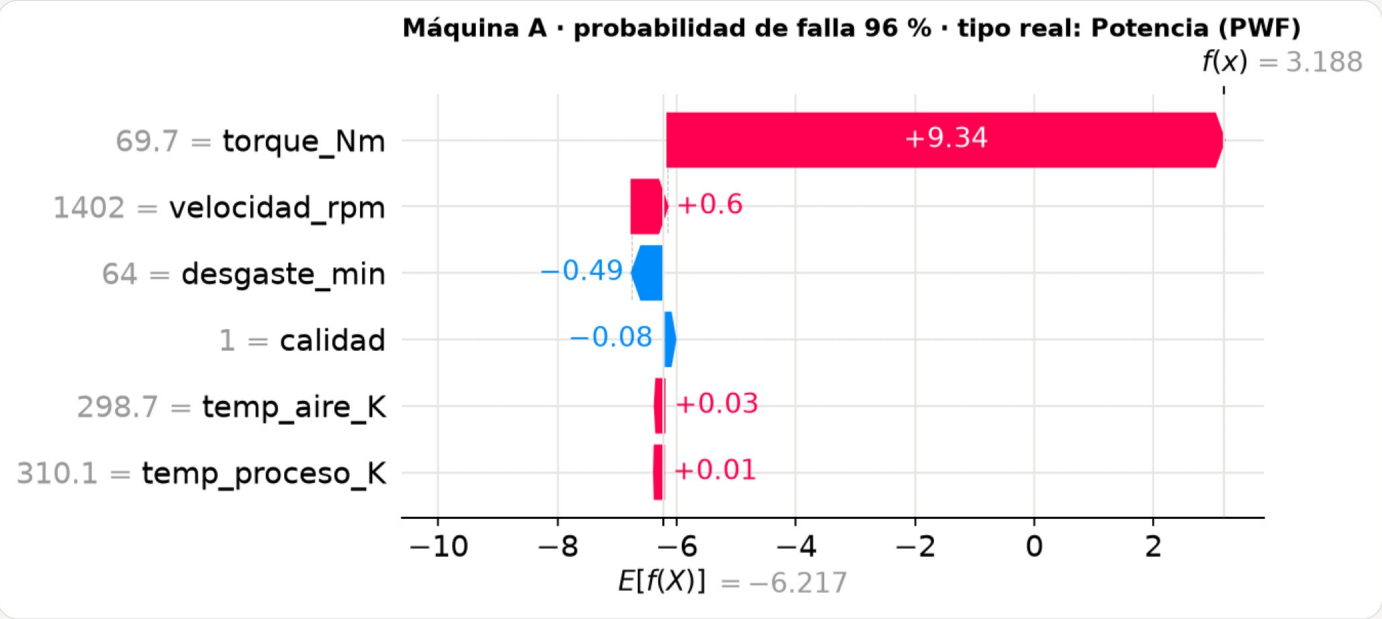
Color: rojo es un valor alto de la variable; azul, bajo.

Lectura: desgaste alto, torque extremo y velocidad baja suben el riesgo.

Valores SHAP de las 2.500 máquinas de prueba, en log-odds

EJEMPLO EN PYTHON

La vista local: por qué esta máquina



Cómo se lee la cascada

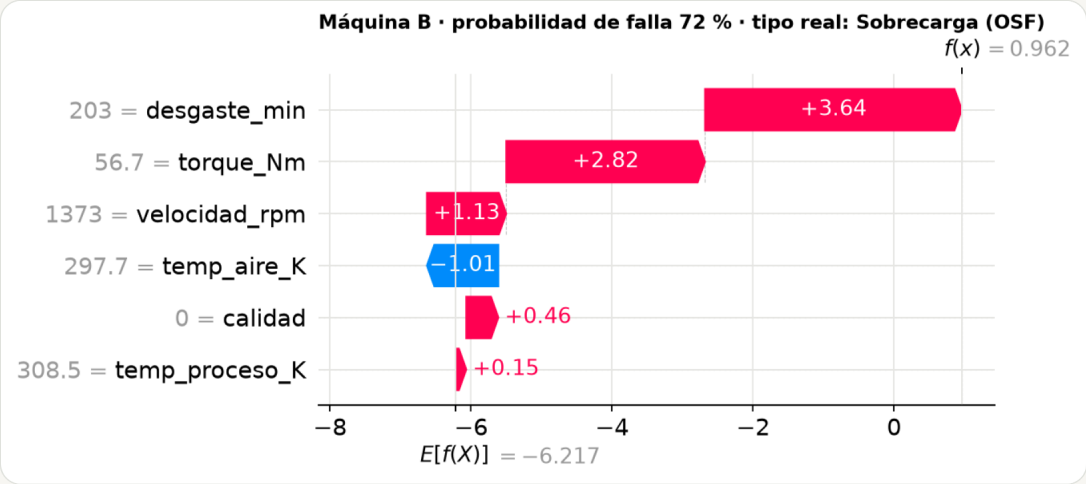
1. Abajo: la predicción para una máquina típica.
2. Cada barra es una variable. Roja empuja hacia falla; azul, en contra.
3. Arriba: la predicción para esta máquina.

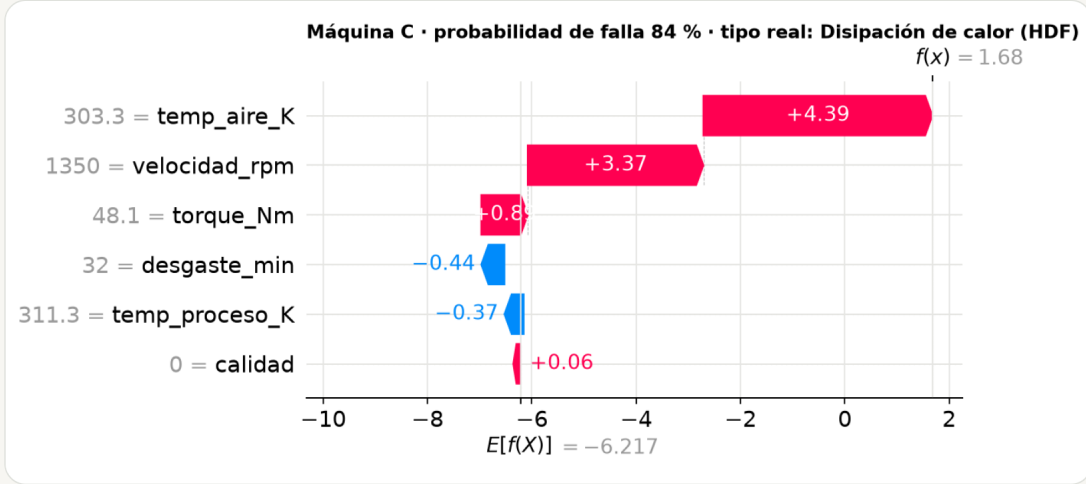
Máquina A: casi todo el riesgo viene del torque (69,7 Nm) con velocidad baja.

Escala en log-odds: 3,19 equivale a 96 % de probabilidad de falla

EJEMPLO EN PYTHON

Tres alertas iguales, tres causas distintas



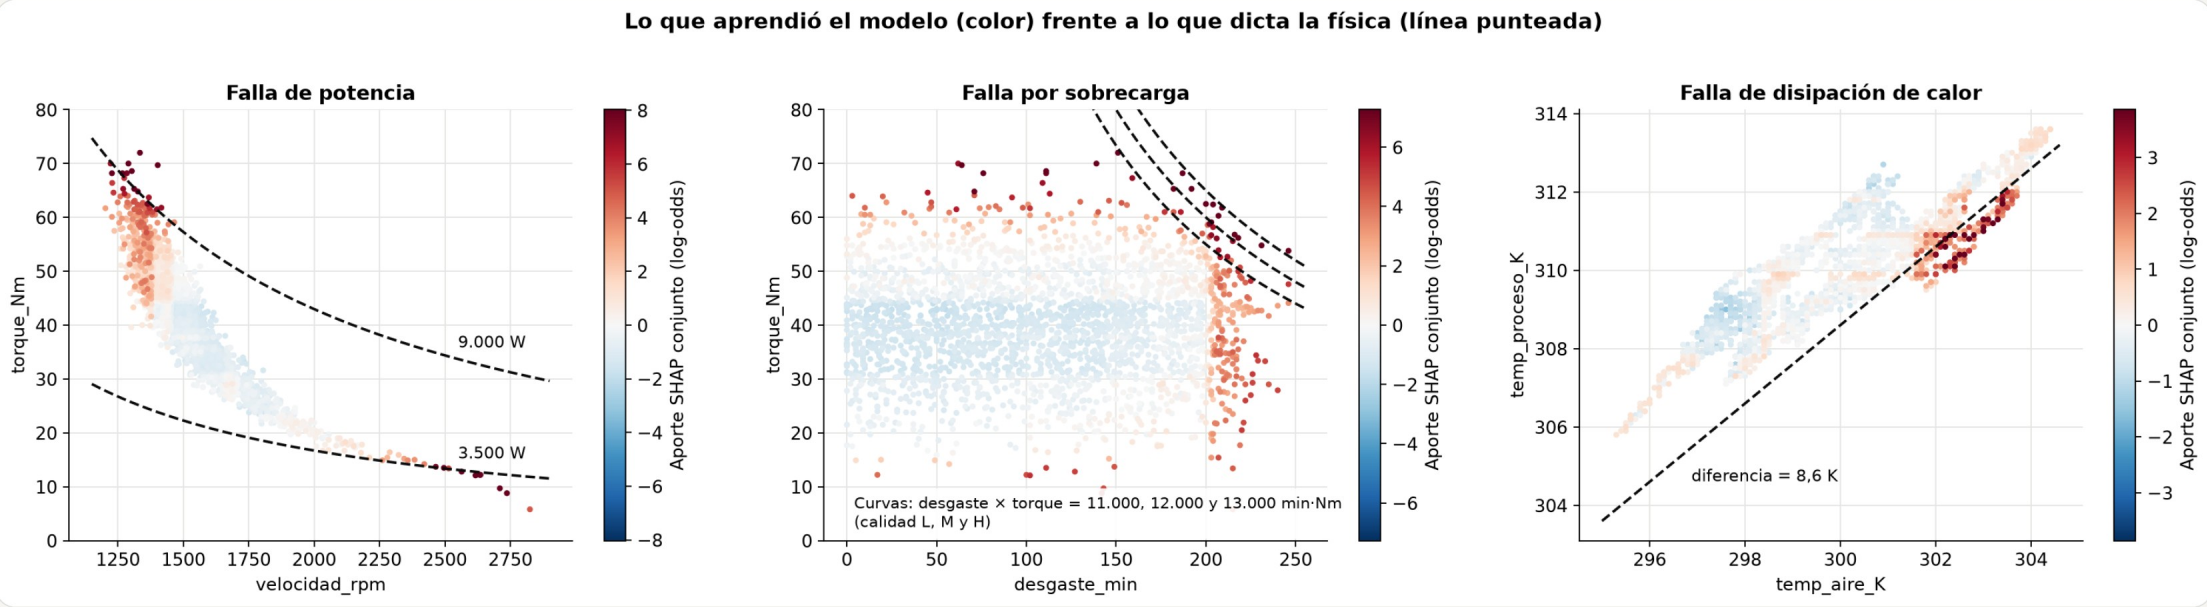


Máquina	Qué señala SHAP	Qué revisa el ingeniero
A · 96 %	Torque muy alto con velocidad baja	La carga: se exige demasiada potencia
B · 72 %	Desgaste alto junto con torque alto	La herramienta: cambiarla antes de seguir
C · 84 %	Temperatura del aire alta y velocidad baja	La refrigeración: el calor no se disipa

Primera falla detectada de cada tipo en el conjunto de prueba

EJEMPLO EN PYTHON

La prueba de fuego: explicaciones contra la física real



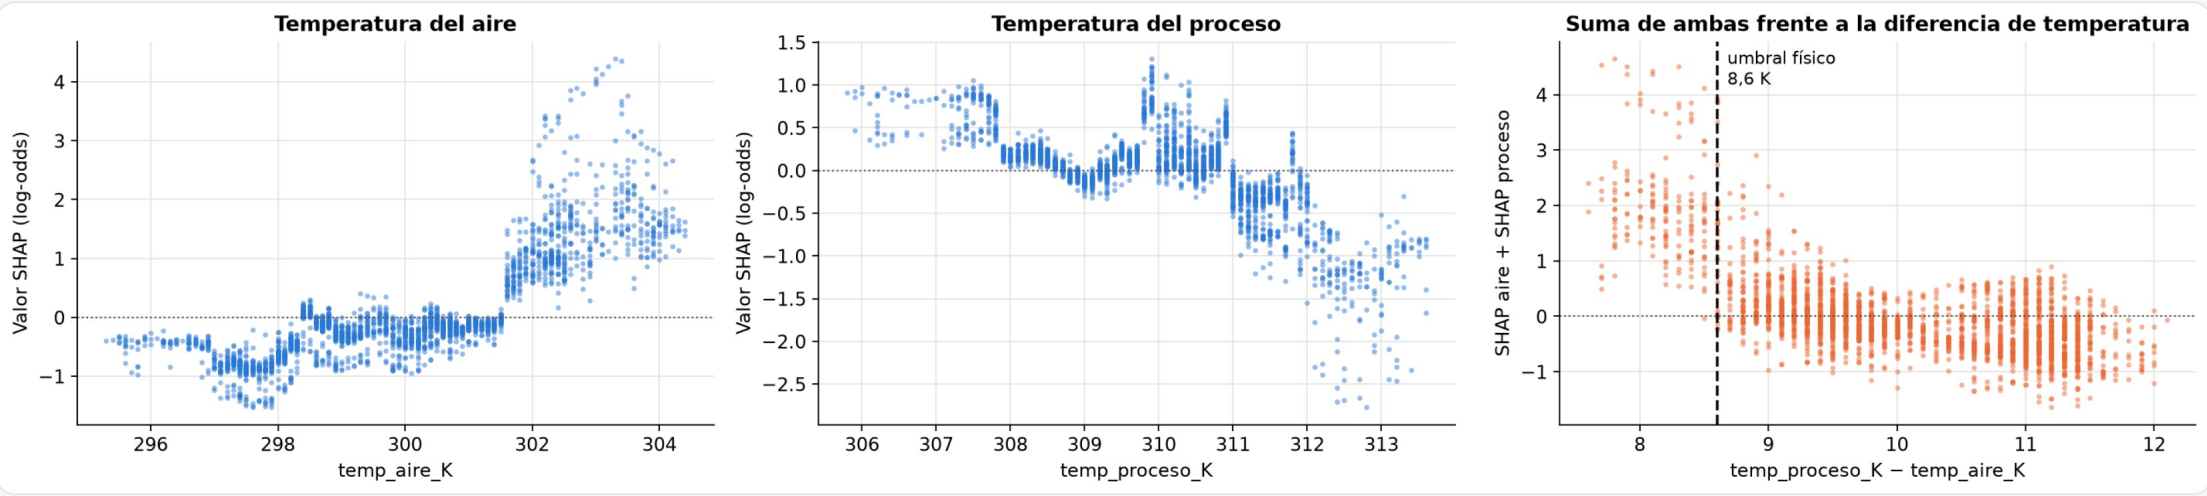
89–100 % la variable principal de SHAP es una causa física real

80–92 % las dos principales lo son, según el tipo de falla

El modelo nunca vio las fórmulas ni el tipo de falla.

Color: lo que aprendió el modelo · Línea punteada: la regla física · Grupos de 12 a 35 fallas por tipo

Las variables correlacionadas confunden la lectura



Lo que parece

El aire caliente sube el riesgo y el proceso caliente lo baja.

Lo que es

Un solo fenómeno: la diferencia de temperatura, con un salto en 8,6 K.

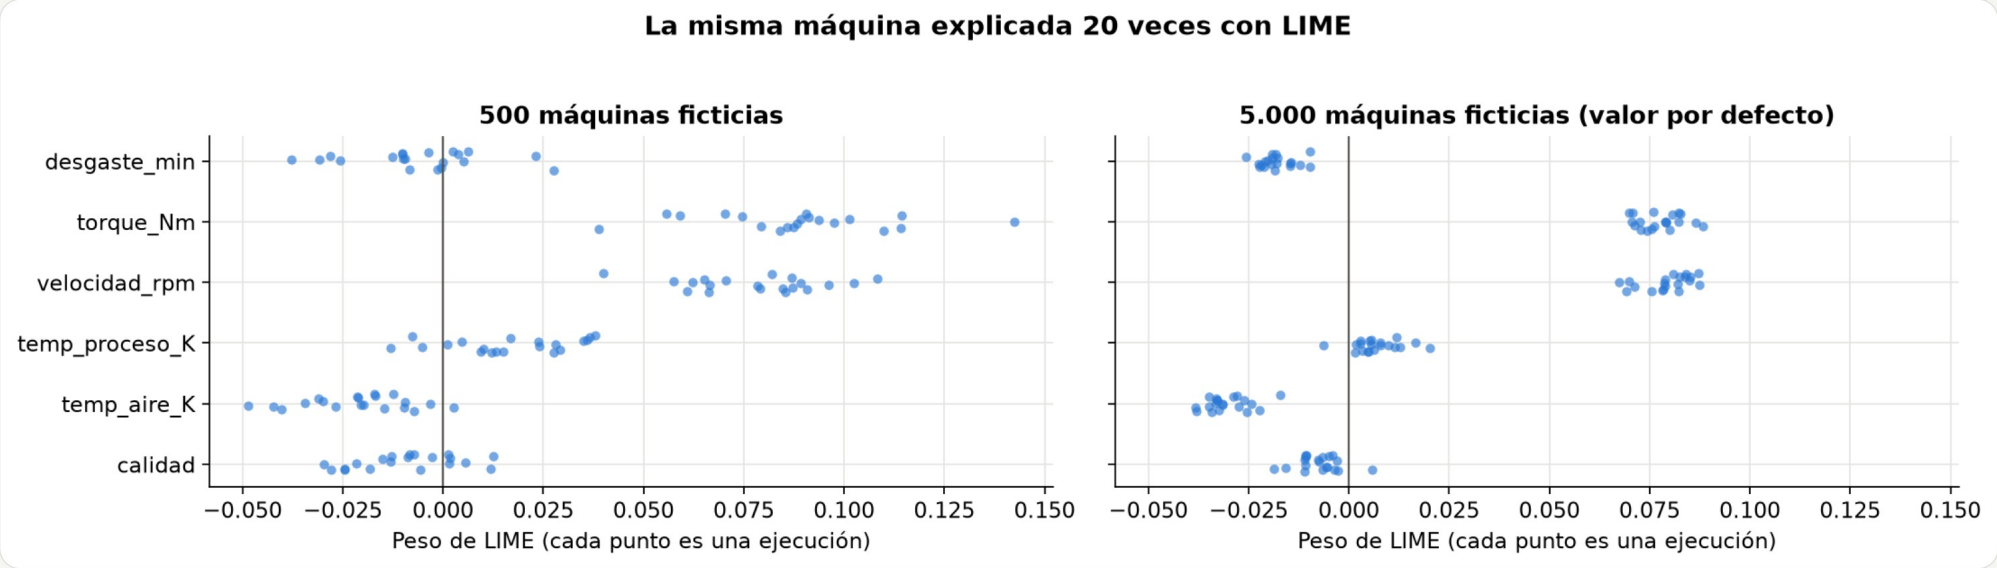
Y además

Al barajar una sola temperatura, el 38 % de las máquinas queda con valores imposibles.

Correlación entre las dos temperaturas: 0,88

RIESGOS DE USO · 2 DE 3

LIME puede ser inestable y poco fiel



0,04 a 0,14
peso del torque según la semilla, con 500 muestras

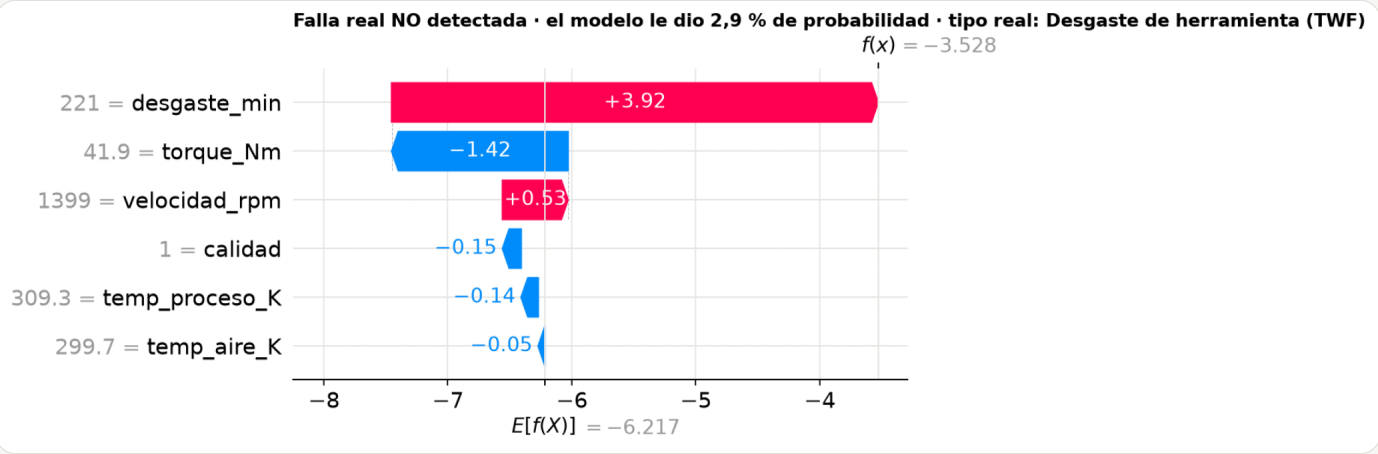
$R^2 \approx 0{,}10$
ajuste del modelo lineal local a la caja negra

13 % frente a 96 %
probabilidad según el modelo local y según XGBoost

Máquina A explicada 20 veces; solo cambia la semilla aleatoria

RIESGOS DE USO · 3 DE 3

Una explicación convincente no valida la predicción



Esta máquina falló. El modelo le dio 2,9 %.

El gráfico se ve tan ordenado como los anteriores. De las 13 fallas por desgaste de herramienta, el modelo dejó pasar 12: son aleatorias por diseño.

SHAP explica el modelo, no el mundo.

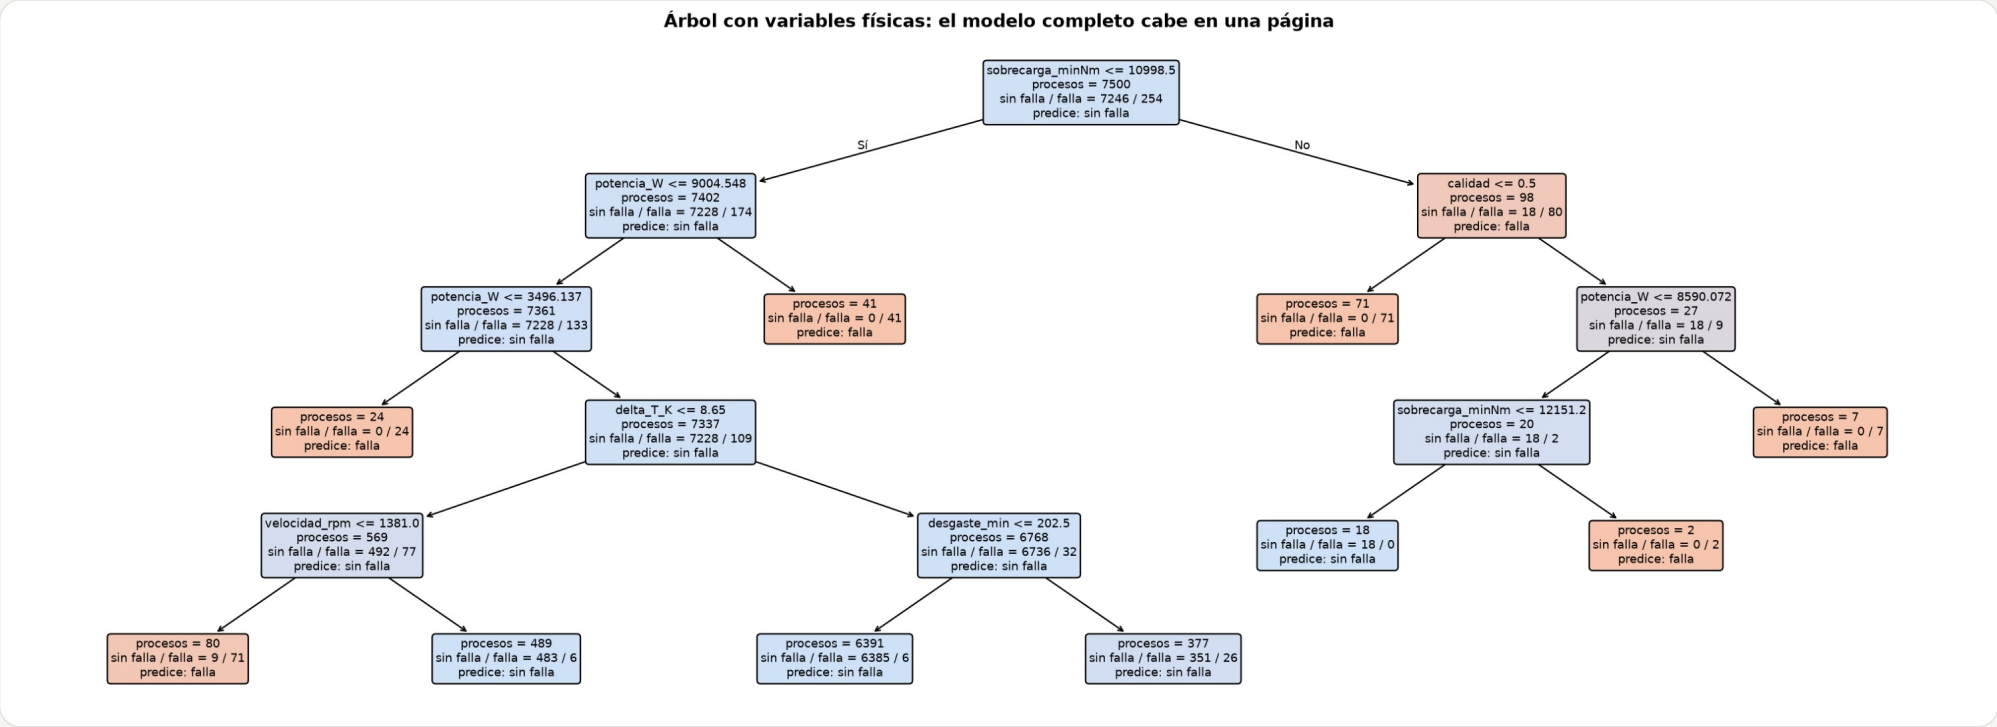
Explicar no es demostrar causalidad.

Métricas y explicaciones se miran juntas.

Falla por desgaste de herramienta: ocurre al azar entre 200 y 240 minutos de uso

CERRAR EL CICLO

Tres variables físicas y un árbol que se lee completo



Potencia = torque × velocidad

Sobrecarga = desgaste × torque

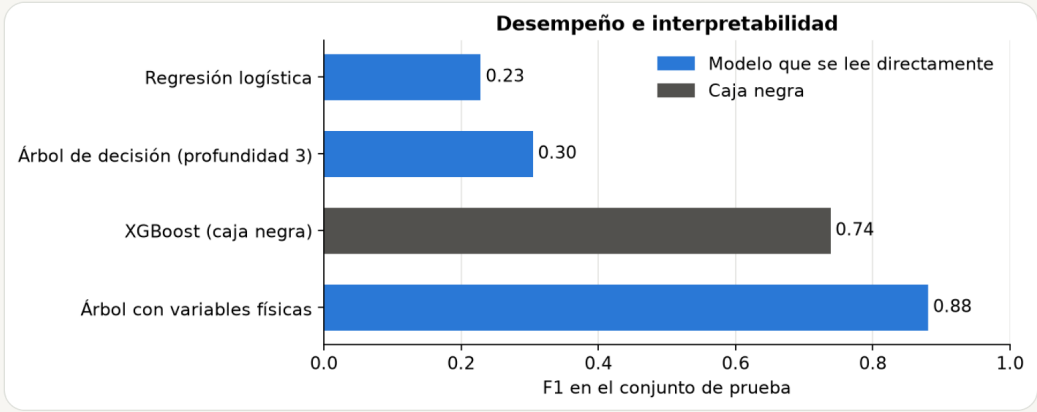
ΔT = temperatura del proceso – del aire

Azul: predomina «sin falla» · Naranja: predomina «falla» · Profundidad elegida por validación cruzada

CERRAR EL CICLO

El árbol supera a la caja negra y encuentra los umbrales

Regla física	Real	Aprendido
Sobrecarga, calidad L	11.000	10.998,5
Sobrecarga, calidad M	12.000	12.151,2
Potencia máxima (W)	9.000	9.004,5
Potencia mínima (W)	3.500	3.496,1
Diferencia de temperatura (K)	8,6	8,65
Velocidad (rpm)	1.380	1.381



Con validación cruzada: F1 de 0,89 para el árbol frente a 0,72 de XGBoost con las variables originales.

Matiz: el dataset es sintético y conocíamos la física. En datos reales, con ruido y reglas desconocidas, la caja negra puede conservar ventaja.

APLICACIONES REALES

Dónde se usa XAI fuera de este ejemplo

Crédito

Negar un crédito exige dar razones concretas. En EE. UU. lo ordena la ley de igualdad de oportunidades de crédito (ECOA).

Salud

Un modelo de riesgo de neumonía aprendió que el asma reducía el riesgo. Un modelo interpretable permitió verlo y corregirlo.

Industria

En mantenimiento predictivo, la explicación convierte una alerta en una orden de trabajo y permite validar el modelo con los ingenieros.

Regulación

El Reglamento de IA de la Unión Europea (2024) exige transparencia y supervisión humana en los sistemas de alto riesgo.

Fuentes: Caruana et al. (2015); Matzka (2020); Reglamento (UE) 2024/1689

CONCLUSIONES

Qué nos llevamos

1. **Predecir no basta.** Una alerta sin explicación no se convierte en una acción.
2. **Las explicaciones se pueden validar.** Aquí SHAP señaló la causa física real en la gran mayoría de los casos.
3. **XAI tiene riesgos propios.** Explica al modelo, no a la realidad, y no demuestra causalidad.
4. **XAI con conocimiento de ingeniería** produjo un modelo mejor y más simple que la caja negra.

REPOSITORIO Y REFERENCIAS

¿Preguntas?

CÓDIGO, DATOS Y NOTEBOOK EJECUTADO

https://github.com/tomasguzman0925-ship-it/AXL

- Matzka (2020). Explainable Artificial Intelligence for Predictive Maintenance Applications. AI4I.
- Lundberg y Lee (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.
- Ribeiro, Singh y Guestrin (2016). "Why Should I Trust You?". KDD.
- Rudin (2019). Stop explaining black box machine learning models for high stakes decisions. Nature Machine Intelligence.
- Hooker, Mentch y Zhou (2021). Unrestricted permutation forces extrapolation. Statistics and Computing.
- Caruana et al. (2015). Intelligible Models for HealthCare. KDD.
- Molnar. Interpretable Machine Learning (libro abierto).