Active Learning

Cómo optimizar el entrenamiento de IA superando el cuello de botella del etiquetado.

Alejandro Rendón Correa

¿Qué podemos hacer cuando el etiquetado es el cuello de botella?

Datos abundantes

Etiquetado lento

Expertos necesarios

Speech Recognition



Chequeo de expertos en biomedicina



CBIR (Recuperación de imagenes basada en contenido)



Active Learning: el modelo decide qué aprender

La supervisión se concentra donde puede cambiar la decisión.

Pasivo

Muestreo aleatorio. El modelo recibe datos sin escogerlos.

Activo

Selección inteligente e interactiva. El modelo pide las instancias más informativas.

1 · Selecciona

El algoritmo identifica una instancia relevante.

2 · Consulta

Un oráculo humano o de referencia responde.

Pool-based active learning cycle



Conjunto etiquetado L

De estos datos etiquetados, el modelo entrena.



Pool U

Pool de datos no etiquetados.



Oráculo

Responde a la consulta.



Función

Determina que instancia evaluar

Repetir hasta alcanzar el presupuesto o la precisión objetivo.

Pool-based active learning cycle

1. Se evalúa la función en el pool

función f(x).
Se evalúa f(U)

2. Se le pregunta al oráculo

f(u) es una instancia, “la de más información”. Se le pregunta al oráculo la etiqueta de esa instancia



3. Se añade la instancia etiquetada

Una vez el oráculo responde con la etiqueta, se añade esta instancia a L

4. Se reentrena al modelo

A partir del nuevo L, el modelo se vuelve a entrenar

Analogía sencilla

Imaginen que son un estudiante que debe estudiar para un parcial de sumas, restas, multiplicación y división

Ejercicios

1. 2 + 6 - 4

2. (10-8)/5

3. (4+9) x (5-3)

4. 5 x 3

De esa misma forma funciona el active learning

1. Ejercicios - Datos.

U y L

2. Profesor - Oráculo

3. Ustedes - el modelo

4. Decidir qué preguntar – La Función

Paradigmas del active learning

Membership Query Synthesis

Mecanismo:

El modelo genera datos sintéticos totalmente nuevos dentro del espacio de entrada

Ejemplo real:

Enter Adam, the Robot Scientist

Stream-Based Selective Sampling

Mecanismo:

Muestrea datos de una distribución real, evaluándolos de uno en uno de forma secuencial

Ejemplo real:

Datos de sensores

Ejercicio practico para entender las funciones

Rapidamente... dividamonos en dos grupos

Detector de sociabilidad animal

Tres estrategias convierten la duda en una regla de selección.

Carasteristicas X

1. Dieta
2. Actividad
3. Hábitat
4. Cuidado de crías
5. Tamaño

La etiqueta Y

Determinar si el animal vive en manada o no

El límite

Pueden hacer 4 preguntas al oráculo, por las etiquetas de animales

¿Qué hicimos?

Tres estrategias convierten la duda en una regla de selección.

Uncertainty Sampling

Prioriza la mayor entropía o menor confianza.

Pregunta donde el modelo duda más.

Query-By-Committee

Consulta donde sus submodelos más discrepan.

Pregunta donde el comité no coincide.

Density-Weighted

Combina duda y representatividad para evitar outliers.

Pregunta algo dudoso que represente a muchos.

Proyecto

Ejercicio de comparación entre selección aleatoria y selección inteligente.

Preguntar bien vale más que acumular datos a ciegas

Más precisión

Con menos costo de etiquetado.

Buen equilibrio

Exploración, incertidumbre y representatividad.

Contexto primero

Adapta la estrategia al oráculo, al presupuesto y al flujo de datos.

La teoría se complica en el mundo real

Batch-mode

Elegir lotes informativos y diversos, no una sola instancia cada vez.

Oráculos ruidosos

Fatiga, errores y crowdsourcing pueden degradar la respuesta.

Costos variables

Cada etiqueta puede tener un precio distinto.

Sesgo de reutilización

Los datos reflejan al modelo que los eligió.

Desafíos prácticos sintetizados por Settles (2011).