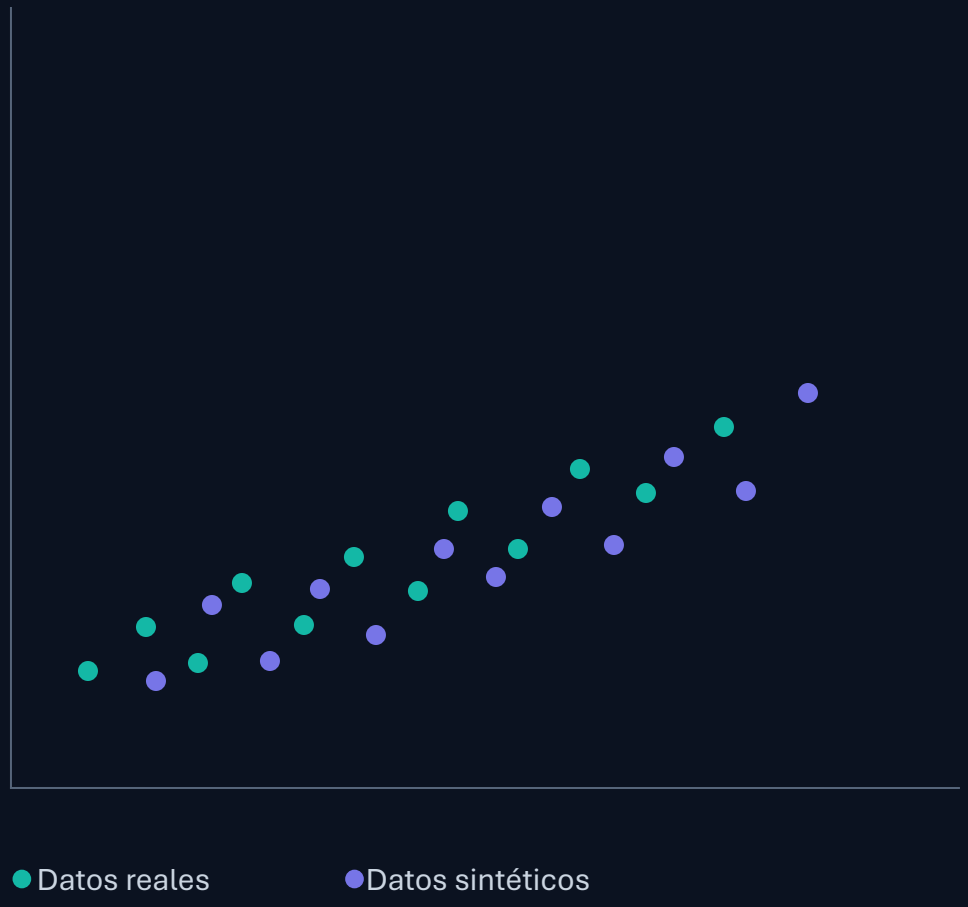
UNIVERSIDAD EAFIT / APRENDIZAJE AUTOMÁTICO

SYNTHETIC DATA

Datos artificiales, aplicaciones reales.



Universidad EAFIT · Aprendizaje Automático · 2026-2

Autor: Vladlen Shatunov

Profesor: Andrés Vásquez Restrepo

¿Y si no tenemos suficientes datos?

Escasez de datos
Hay pocos registros para aprender un patrón fiable.



Privacidad sensible
Compartir registros personales puede exponer información.



Recolección y etiquetado
Obtener ejemplos útiles requiere tiempo y recursos.



Clases poco representadas
Las categorías infrecuentes quedan subrepresentadas.



Obtener datos suficientes, representativos y seguros no siempre es posible.

Representaciones conceptuales de dificultades en entrenamiento.

¿Qué son los datos sintéticos?

Datos creados artificialmente mediante reglas, simulaciones o modelos estadísticos y generativos. Pueden reproducir características y patrones de los datos reales.

Datos reales

ID	Medida A	Medida B
R1	4,8	1,4
R2	5,1	1,6
R3	4,9	1,5

Ejemplo ilustrativo; no son registros Iris.

→

GENERADOR

Aprende reglas o distribuciones

→

Datos sintéticos

ID	Medida A	Medida B
S1	4,9	1,4
S2	5,0	1,6
S3	4,7	1,5

Valores ilustrativos; no son un resultado.

No son simplemente números aleatorios.

¿Qué tipos de datos sintéticos existen?

Datos tabulares

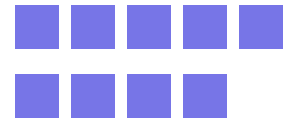
Filas y columnas artificiales que preservan relaciones.

A	B	clase
4	7	1
5	8	1

FOCO DEL EXPERIMENTO

Imágenes sintéticas

Píxeles o escenas creadas para tareas de visión.



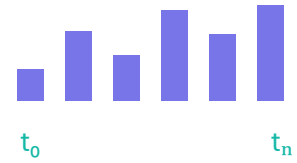
Texto sintético

Frases y documentos para probar sistemas de lenguaje.

«Consulta...»
«Respuesta...»
«Resumen...»

Series temporales sintéticas

Secuencias que mantienen dependencia temporal.



Representaciones esquemáticas; no son datos del experimento.

¿Cómo se generan los datos sintéticos?

Basados en reglas

Generamos datos siguiendo condiciones previamente definidas.

SI condición → registro

Estadísticos

Aprendemos características y relaciones de los datos.

μ, Σ → muestra nueva

Modelos generativos

Aprendemos patrones con modelos avanzados (GAN y VAE).

datos → modelo

EN IRIS: utilizamos el método estadístico.

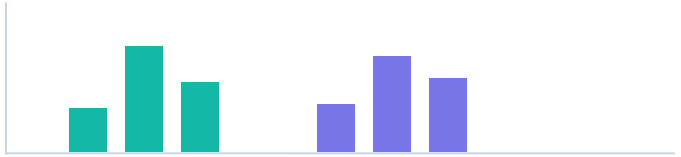
Alternativas; no son etapas obligatorias.

Detalle Iris: medias (μ) y covarianzas (Σ) por especie, solo del entrenamiento.

¿Cómo sabemos si los datos sintéticos son buenos?

Fidelidad

¿Se parecen a los datos reales?
Comparamos propiedades estadísticas.



Utilidad

¿Sirven para entrenar un modelo?
Lo probamos con datos reales no vistos.

Entrena sintético → prueba real

Privacidad

¿Pueden revelar información sensible?
Evaluamos el riesgo de privacidad.



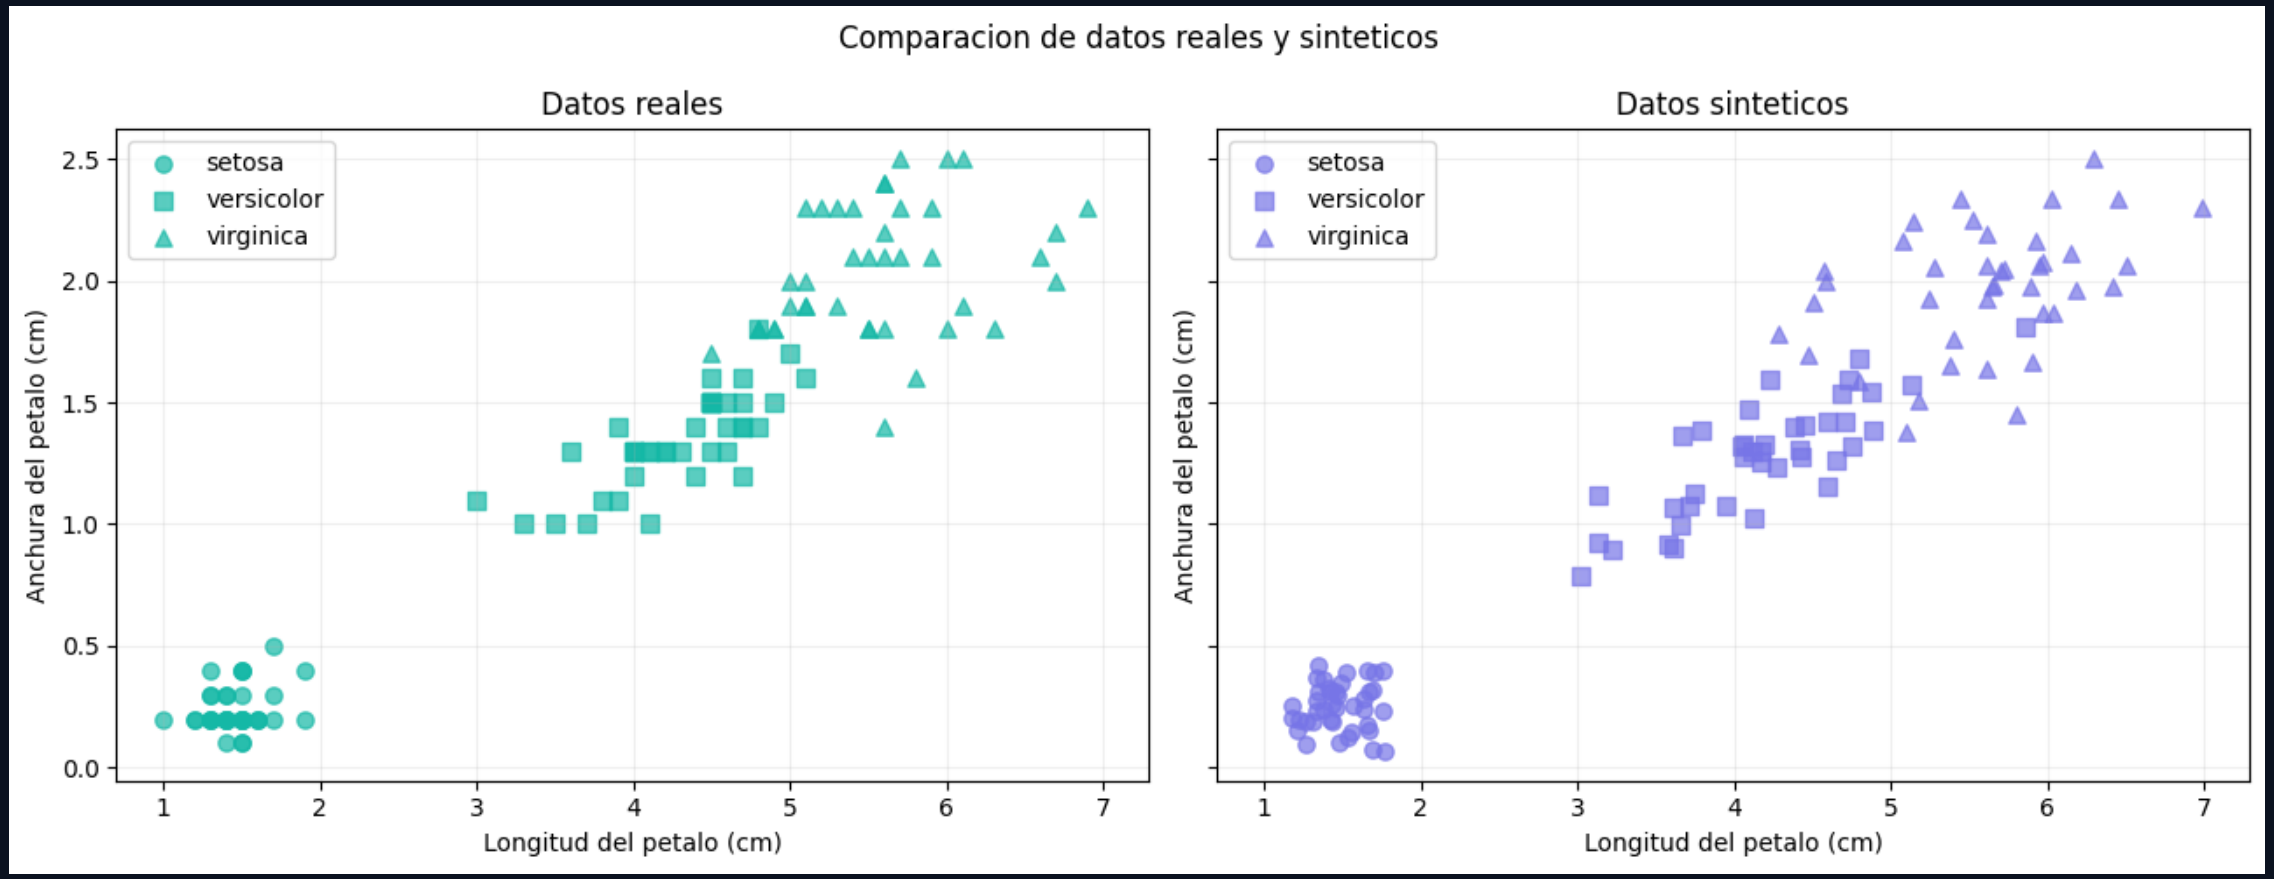
¿Coincidencia o inferencia?

Parecerse a los datos reales no garantiza ser igual de útiles ni seguros.

NIST: Task, Bhagat y Howarth, SDNist v2 (2023), doi:10.18434/mds2-2943

¿Puede un modelo aprender con datos artificiales?

150 flores → 120 para entrenar + 30 para probar



De 120 reales generamos 120 sintéticas. Parecerse no demuestra utilidad.

Fuente: elaboración propia. Dataset Iris (Scikit-learn).

¿Cómo comparamos datos reales y sintéticos?

Iris · 150 flores · división estratificada 80/20 · semilla 2026

Iris · 150 flores
4 variables · 3 especies

1 · SEPARAMOS DATOS
120 para entrenar + 30 para probar

TRAIN · 120 flores reales
40 por especie

TEST REAL · 30 flores
10 por especie · reservado

2 · GENERAMOS 120 FLORES SINTÉTICAS

Solo TRAIN: medias y covarianzas por especie → normal multivariada

3 · MODELO B: 120 sintéticas → StandardScaler → KNN (k=3)

3 · MODELO A · ENTRENAMIENTO REAL

120 reales → StandardScaler → KNN (k=3) → Modelo A

EVALUACIÓN · MISMAS 30 REALES

A y B responden sobre las mismas 30 flores reales no vistas.

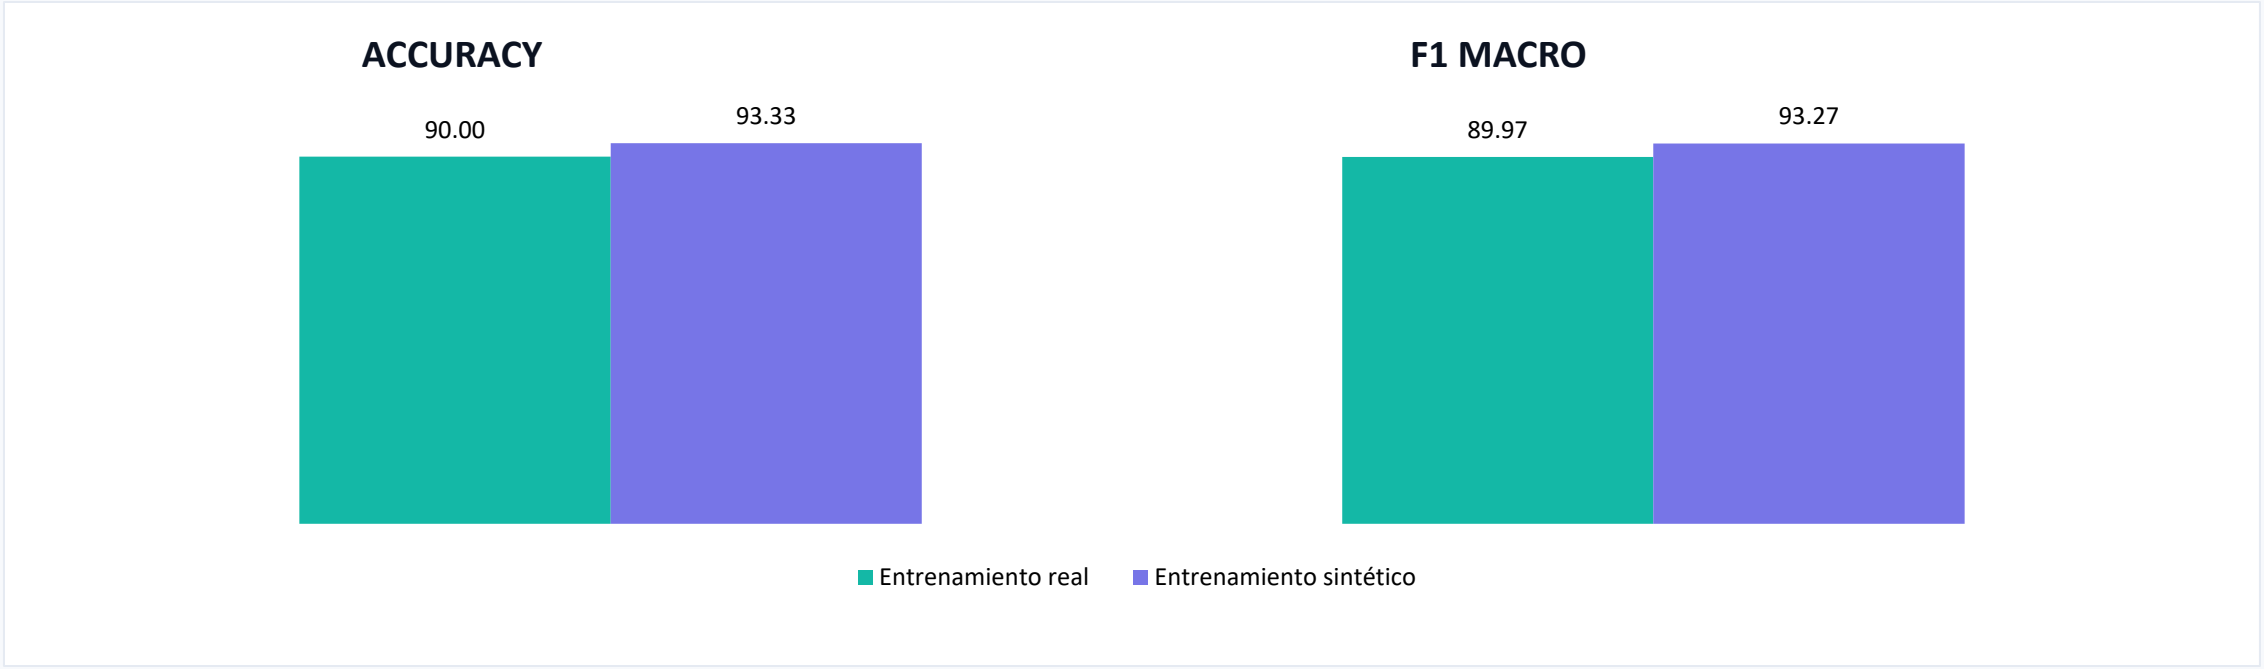
Accuracy · F1 macro

El TEST nunca genera ni entrena. Cada modelo usa un Pipeline: StandardScaler + KNN.

Fuente: elaboración propia. Dataset Iris (Scikit-learn) · documentación oficial scikit-learn.

¿Cuántas flores clasificó cada modelo?

Una prueba con 30 flores reales · KNN (k=3) · F1 macro: real 0,8997; sintético 0,9327



DATOS REALES · Accuracy 90,00 % · 27/30 aciertos

DATOS SINTÉTICOS · Accuracy 93,33 % · 28/30 aciertos

El modelo sintético clasificó correctamente una flor adicional.

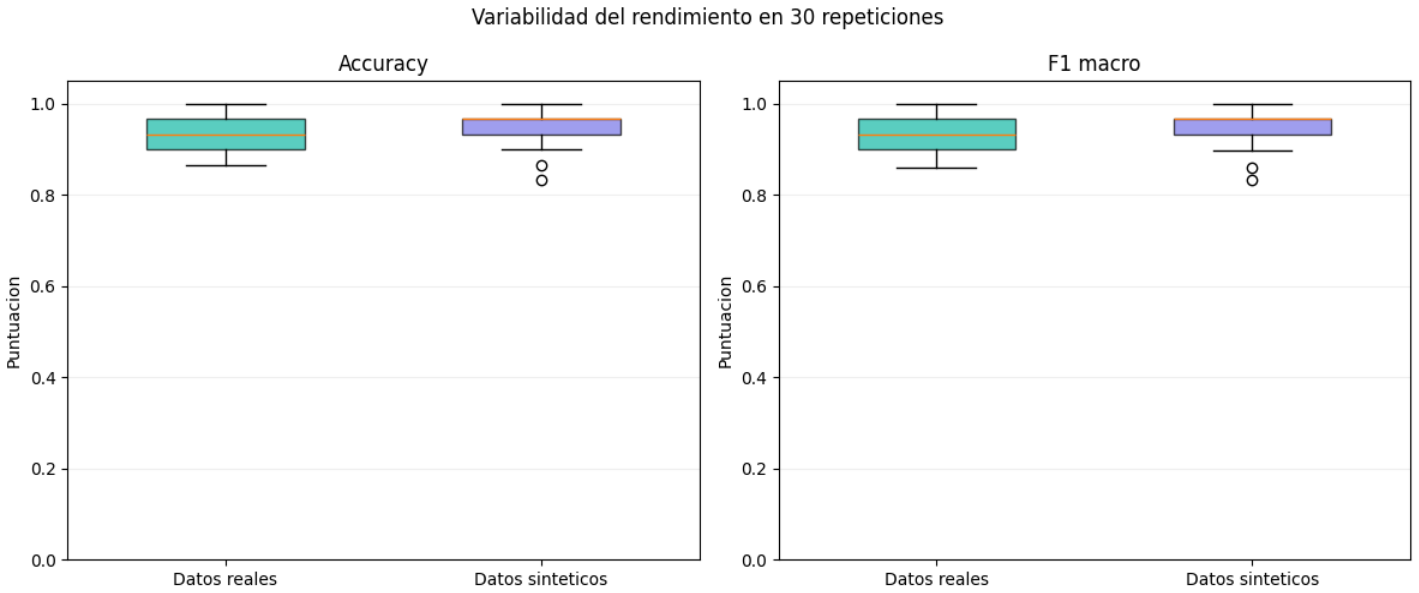
Una sola división no demuestra superioridad entre modelos.

Fuente: elaboración propia. Dataset Iris (Scikit-learn) · prueba real n=30 · semilla 2026

Ambos modelos mantuvieron resultados similares

Repetimos el experimento 30 veces con divisiones estratificadas

VARIABILIDAD · ACCURACY Y F1 MACRO



PROMEDIOS · 30 REPETICIONES

DATOS REALES

Accuracy promedio 93,33 % · F1 macro 0,9332

Desv. Accuracy 0,0401 · F1 0,0403

DATOS SINTÉTICOS

Accuracy promedio 94,56 % · F1 macro 0,9451

Desv. Accuracy 0,0376 · F1 0,0382

MAYOR ACCURACY / REPETICIÓN

3	12	15
Real	Sintético	Empates

Rendimiento similar: el sintético promedió algo más, sin demostrar superioridad general.

30 divisiones StratifiedShuffleSplit; regenerar y entrenar solo con train. Pruebas solapadas.

Fuente: elaboración propia. Dataset Iris (Scikit-learn) · boxplots y promedios de las 30 divisiones.

¿Dónde se utilizan los datos sintéticos?

	ÁREA	PROBLEMA	POSIBLE UTILIDAD
01	**Salud**	Registros clínicos sensibles.	→ Investigar reduciendo exposición; verificar privacidad.
02	**Finanzas**	Transacciones poco frecuentes.	→ Simular casos para probar detección y procesos.
03	**Software**	Pruebas con datos reales riesgosos.	→ Crear escenarios artificiales para verificar sistemas.
04	**Simulación**	Situaciones difíciles de observar.	→ Explorar escenarios bajo supuestos explícitos.

Posibles usos; no son estadísticas de adopción ni garantías de calidad.

Sintético no significa perfecto

Una distribución puede distorsionarse

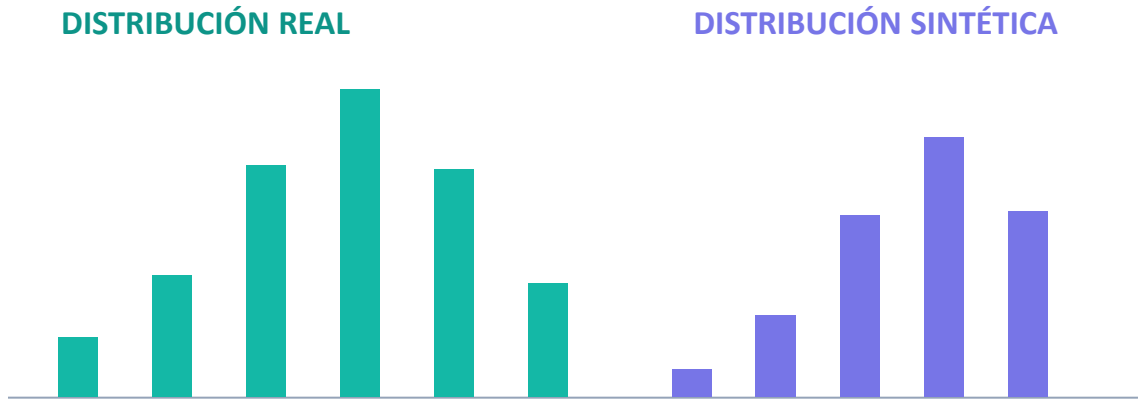


Ilustración conceptual: cambio de forma y posición (sin escala).

01 Reproducción de sesgos

02 Distorsión de distribuciones

03 Riesgos de privacidad

04 Límites de generalización

La calidad de los datos sintéticos debe demostrarse, no asumirse.

NIST: Task, Bhagat y Howarth, SDNist v2 (2023), doi:10.18434/mds2-2943

Los datos pueden ser artificiales. Su utilidad debe ser real.

01 El generador estadístico conservó aproximadamente patrones de Iris.

02 El entrenamiento sintético logró rendimiento comparable al real.

03 La utilidad se comprueba en datos reales no vistos.

04 No hay evidencia de superioridad general; evaluar fidelidad y riesgos.



¿Cuándo confiarías en un modelo entrenado con datos que nunca existieron?