


Series de tiempo, forecasting tabular y walk-forward validation

Aprendizaje Automático · Sesión 3



Andrés Vásquez Restrepo

`avasquezr3@eafit.edu.co`

SI7009 - 1 (5553)

Universidad EAFIT

2026-2 – Medellín

Contenido

1. El tiempo cambia el experimento
2. Leer la estructura temporal
3. Formulación: target y horizonte
4. Windowing: de serie a tabla supervisada
5. Features: lags, rolling y calendario
6. Modelos globales
7. Baselines temporales
8. Validación temporal y leakage
9. Métricas y multi-horizonte
10. Modelos, notebook y demo
11. Cierre

Dónde quedamos

El tiempo ya apareció en el curso: hoy se vuelve el centro

Sesiones 1 y 2

- S1: `TimeSeriesSplit` como CV temporal "si las features tienen cronología";
- S2: el fold de Optuna depende de los datos (estratificado o temporal);
- baseline serio, leakage dentro de la validación.

Ruta: estructura → formulación → windowing → features → modelo global → baselines → validación → métricas → modelos y hands-on.

Idea clave: Hoy

Predecir el futuro sin mirarlo: **una serie** (tráfico Metro) para el método y **muchas series** (consumo eléctrico) para el modelo global.

El tiempo cambia el experimento

La pregunta central de esta sesión

El problema no es tener fechas; es predecir sin mirar el futuro

En datos temporales, un score alto no demuestra valor si el experimento permitió mirar el futuro.

$$y_1, y_2, \dots, y_t, \dots, y_T \qquad \hat{y}_{t+h} = f(X_t) \text{ con } X_t \text{ disponible solo hasta } t$$

- El **orden** define qué información era observable: las filas ya no son intercambiables.
- El **horizonte** define qué tan lejos queremos predecir.
- La **validación** define si el score representa operación real.

Lo aprendido antes se vuelve más exigente

¿El modelo habría tenido esta información en el momento real en que debía predecir?
Si no, el resultado está inflado aunque el código sea correcto.

Chequeo inicial: ¿qué podía saber el modelo?

Antes de entrenar, audite la disponibilidad de información

Taller / tarea: **Discusión breve**

Queremos predecir el volumen de tráfico una hora adelante. Para una predicción hecha a las 8:00 AM, decida qué información es válida.

1. Volumen observado a las 7:00 AM.
2. Promedio de tráfico entre 8:00 AM y 10:00 AM.
3. Hora del día y día de la semana.
4. Clima reportado después del periodo objetivo.
5. Volumen de la misma hora del día anterior.

Una columna histórica solo es válida si su versión operacional existía antes de la predicción.

Antes de modelar: leer la estructura temporal


Una serie de tiempo no es solo una fecha

Es una señal ordenada con memoria, ciclos y posible cambio

$$y_t = T_t + S_t + R_t$$

- T_t : **tendencia**, cambio lento del nivel;
- S_t : **estacionalidad**, patrón repetido;
- R_t : **residuo**, lo que queda sin explicar.

Si se pierde el **orden**, se pierde la estructura que hace posible el forecasting.




Cuidado

La descomposición ayuda a leer tendencia y ciclos; la evidencia predictiva sigue dependiendo de validación hacia adelante.

Frecuencia y granularidad

La pregunta cambia si los datos son horarios, diarios o mensuales

Frecuencia	Riesgo frecuente
Horaria	confundir ciclos diarios con ruido
Diaria	ignorar fines de semana y eventos
Semanal	tener pocos puntos por ciclo
Mensual	sobreinterpretar series cortas




Regla: La frecuencia define qué *lags*, ventanas, estacionalidades y métricas tienen sentido.

Autocorrelación: memoria estadística

El pasado puede seguir hablando en el presente

$$\rho_k = \text{CORR}(y_t, y_{t-k})$$

- **ACF:** ρ_1 alto sugiere persistencia; ρ_{24} alto en datos horarios, ciclo diario;
- **PACF:** correlación con y_{t-k} descontando los lags intermedios; sugiere qué lags aportan algo propio;
- orienta lags y baselines; no prueba causalidad.



Uso práctico

Si ρ_s es alto (por ejemplo $s = 24$), el lag estacional y_{t-s} y el seasonal naïve merecen probarse antes de entrenar modelos complejos.

Checklist de diagnóstico antes de modelar

El modelo no debe ser la primera herramienta

Antes de entrenar, responda

1. ¿Cuál es la frecuencia real de la serie?
2. ¿Hay huecos, duplicados o cambios de granularidad?
3. ¿Hay tendencia visible?
4. ¿Hay estacionalidad diaria, semanal o anual?
5. ¿La ACF sugiere persistencia o ciclos?
6. ¿El baseline seasonal naïve parece competitivo?
7. ¿El horizonte elegido coincide con la decisión operativa?

Una serie de tiempo se entiende primero como fenómeno; solo después como matriz de entrenamiento.

Target temporal, predicción y horizonte

"Predecir tráfico" no es una formulación completa

El target pertenece al futuro; las features pertenecen al pasado disponible

$$\hat{y}_{t+h} = f(X_t)$$

t

momento en que el sistema debe tomar la predicción.

h

horizonte: distancia entre predicción y objetivo.

X_t

información conocida hasta t .

y_{t+h}

valor futuro que queremos estimar.

Formulación incompleta

"Predecir demanda" o "predecir tráfico" no alcanza: una formulación temporal fija qué se predice, desde cuándo, con qué información y a qué horizonte.

El horizonte cambia la formulación

Un buen modelo a 1 hora no necesariamente sirve a 24 horas

Horizonte	Pregunta operativa	Lectura metodológica
1 hora	¿Qué pasará casi inmediatamente?	alta dependencia del estado reciente
3 horas	¿Cómo evoluciona el corto plazo?	empieza a importar la tendencia local
6 horas	¿Qué patrón domina medio día operativo?	pueden aparecer ciclos y cambios de régimen
24 horas	¿Qué ocurrirá en el mismo punto del siguiente día?	la estacionalidad diaria puede importar más que el último valor

Taller / tarea: **Práctica**

Complete la formulación (target, momento, horizonte, información): “predecir demanda de bicicletas” y “predecir ventas para inventario”.

El caso aplicado debe servir al método, no al revés

Cada dataset cumple una función pedagógica distinta

Dataset	Por qué sirve	Uso en la sesión
Metro Interstate Traffic Volume	una serie horaria con clima, festivos y estacionalidad diaria	método: horizonte, lags, baselines, walk-forward
UCI Electricity Load Diagrams	consumo horario de muchos clientes con escalas distintas	modelo global frente a modelos locales
Serie sintética y dummy manual	tendencia, ciclo y alineación controlados	random split frente a temporal; alineación lag-target
Bike Sharing	demanda horaria más liviana	respaldo pedagógico

El *dataset* no se elige por fama; se elige porque permite demostrar decisiones temporales correctas.

Windowing: de serie temporal a tabla supervisada

Forecasting tabular: cada fila es una decisión en t

El objetivo no es "usar fechas"; es construir filas válidas de predicción

$$\mathbf{z}_t = [y_{t-1}, y_{t-24}, \text{rolling}_{24}(t), \text{calendar}(t), \text{exo}(t)] \longrightarrow y_{t+h}$$

- un modelo tabular no entiende una serie por defecto: hay que convertir el pasado disponible en una fila;
- $\mathbf{z}_t$ contiene solo señales disponibles al momento de predicción;
- y_{t-1} : memoria inmediata · y_{t-24} : referencia estacional diaria;
- $\text{exo}(t)$ debe ser una versión externa disponible en t , no una observación futura.

Error común

Crear columnas temporales sin revisar alineación produce un dataset elegante pero contaminado.

Ejemplo mínimo de alineación

La primera intuición del notebook debe ser manual y visible

Tiempo	y_t observado	lag_1	Target y_{t+1}	Lectura
08:00	120	–	135	no hay historia suficiente para lag_1
09:00	135	120	150	fila válida para predecir 10:00
10:00	150	135	142	fila válida para predecir 11:00
11:00	142	150	–	no conocemos target futuro al construir evidencia histórica

Al desplazar *features* y *target*, algunas filas se pierden. Esa pérdida no es un error: es consecuencia de respetar el tiempo.

Una tabla temporal puede estar mal aunque se vea completa

La validez depende de cómo se construyó cada columna

Fila temporal válida

- usa valores anteriores a t ;
- calcula agregados con ventana histórica;
- incorpora calendario conocido;
- usa variables exógenas disponibles antes de decidir.

Fila temporal contaminada


- usa y_{t+h} directa o indirectamente;
- calcula promedios con datos futuros;
- normaliza usando todo el dataset;
- incluye variables publicadas después del evento.

Regla metodológica

La validez de una feature depende de su disponibilidad operacional, no de su presencia en el archivo.

Ventana deslizante: cómo se arma cada fila

Una ventana de longitud L mira hacia atrás; el objetivo está h pasos adelante



- cada fila desplaza la ventana un paso: la serie se convierte en una tabla **sin mirar el futuro**;
- la longitud L (lookback) es un **hiperparámetro**: se elige con walk-forward, no a ojo;
- ventanas, lags y rolling son la misma idea: resumir el pasado disponible en t .

Ejemplo: de la ventana a la tabla

Serie horaria con ventana $L = 3$ y horizonte $h = 1$

hora	08:00	09:00	10:00	11:00	12:00	13:00	14:00	15:00
y_t	120	135	150	142	160	171	158	149



momento t	y_{t-2}	y_{t-1}	y_t	target y_{t+1}
10:00	120	135	150	142
11:00	135	150	142	160
12:00	150	142	160	171
13:00	142	160	171	158
14:00	160	171	158	149

- cada fila es la ventana anterior desplazada una hora: 8 valores producen 5 filas (se pierden $L - 1$ al inicio y h al final);
- las columnas azules son las **features** (solo pasado); la roja es el **target** (futuro);
- con $h = 3$ el target de la fila 10:00 sería $y_{13:00} = 171$, y se pierden 3 filas al final.

Estrategias multi-paso: predecir varios horizontes

Cómo obtener $\hat{y}_{t+1}, \dots, \hat{y}_{t+H}$ con un modelo tabular

Estrategia	Cómo funciona	Modelos	Riesgo o ventaja
Recursiva	un modelo a 1 paso; su predicción se usa como lag para el siguiente	1	acumula error en horizontes largos
Directa	un modelo distinto para cada horizonte h	H	sin acumulación; más modelos que entrenar
Multi-output	un modelo predice las H salidas a la vez	1	comparte señal entre horizontes

Idea clave: En el notebook

Se usa la estrategia **directa**: un target y_{t+h} por cada $h \in \{1, 3, 6, 24\}$. Es la más fácil de auditar.

Features temporales válidas


Lags y rolling windows convierten memoria en evidencia

Cada feature temporal debe representar pasado disponible

$$\text{lag}_k(t) = y_{t-k}$$

$$\text{rolling_mean}_w(t) = \frac{1}{w} \sum_{i=1}^w y_{t-i}$$

- **lags:** memoria puntual ($\text{lag}_1, \text{lag}_{24}$);
- **rolling:** nivel y variabilidad recientes (media y desviación de 24 h);
- válidos solo si terminan antes de t : `y.shift(1).rolling(w)`.



Leakage

Una ventana que incluye y_t, y_{t+1} o valores posteriores usa el futuro: el score mejora y en producción no se repite.

Feature temporal válida vs feature contaminada

El nombre de la columna no garantiza la validez

Feature	Válida si...	Contaminada si...
lag_1	usa un valor observado antes de predecir	se construye con el target futuro desplazado al revés
lag_{24}	representa la misma hora del día anterior disponible	usa una medición corregida después del periodo objetivo
rolling_mean_{24}	promedia solo valores anteriores al momento t	incluye y_t , y_{t+1} o valores posteriores
clima	pronóstico disponible antes de las 8:00 AM	clima observado oficialmente a las 10:00 AM

Taller / tarea: Práctica

Para una predicción a las 8:00 AM, clasifique como válida, dudosa o contaminada: hora del día, festivo ya conocido, clima observado a las 10:00, pronóstico de las 7:00.

La hora no vive en una recta: vive en un ciclo


El calendario es válido, pero debe codificarse como ciclo

$$\text{hour}_{\sin} = \sin\left(\frac{2\pi \cdot \text{hour}}{24}\right)$$

$$\text{hour}_{\cos} = \cos\left(\frac{2\pi \cdot \text{hour}}{24}\right)$$

- **lineal:** 23 y 0 parecen muy distantes; frontera artificial en medianoche;
- **cíclica:** cada hora es un punto del círculo; 23:00 y 00:00 quedan cerca;
- hora, día, mes y festivos se conocen antes de predecir.

Se necesitan las dos (seno **y** coseno): con una sola, horas distintas tendrían el mismo valor.



Codificación estacional: ciclos cortos y largos

Seno/coseno, términos de Fourier y lags estacionales

Variable	Qué puede capturar	Codificación razonable
Hora del día	ciclos de congestión o actividad	seno/coseno de 24 horas
Día de la semana	lunes frente a fin de semana	categorica o seno/coseno semanal
Estacionalidad larga	ciclo semanal (168 h) o anual	Fourier: $\sin \frac{2\pi kt}{s}, \cos \frac{2\pi kt}{s}, k = 1..K$
Patrón exacto del ciclo	la misma hora del ciclo anterior	lag estacional y_{t-s}
Festivo	cambios programados	indicador binario conocido antes de predecir

Idea clave: Cuándo usar cada uno

Fourier con pocos K describe ciclos largos con pocas columnas; el lag estacional copia la forma exacta del ciclo pero exige historia suficiente.

De una serie a muchas: modelos globales

Local frente a global

Un modelo por serie o un modelo para todas las series

Modelo local

Un modelo f_j por cada serie j : 20 clientes
→ 20 modelos, cada uno con su propia historia.

Modelo global

Un solo f entrenado con las filas de **todas** las series:

$$\hat{y}_{j,t+h} = f(X_{j,t}, \text{id}_j)$$

Qué gana


más datos por modelo · patrones compartidos (horas pico, festivos) · funciona con series nuevas o cortas.

Qué arriesga

series muy distintas entre sí · una serie grande domina la pérdida si no se escala · más difícil de depurar.

Cómo se arma la tabla global

Apilar series sin mezclar sus historias



- columna `series_id` y features estáticas de cada serie (tipo de cliente, región);
- lags y rolling **por serie**: `df.groupby("series_id")["z"].shift(1);`
- **escalar por serie** (dividir por su media histórica, calculada solo en train) para que ninguna domine;
- la identidad de la serie entra como categórica: el modelo puede aprender diferencias de nivel.

Ejemplo: dos clientes, una sola tabla

Consumo horario (kW), lags $L = 2$ y horizonte $h = 1$

hora	10:00	11:00	12:00	13:00	14:00
cliente A (residencial)	50	55	62	58	60
cliente B (comercial)	400	420	480	470	450

⇓ apilar y calcular lags con `groupby("series_id")`

series_id	tipo	hora t	y_{t-1}	y_t	target y_{t+1}
A	residencial	11:00	50	55	62
A	residencial	12:00	55	62	58
A	residencial	13:00	62	58	60
B	comercial	11:00	400	420	480
B	comercial	12:00	420	480	470
B	comercial	13:00	480	470	450

- un solo modelo aprende de las 6 filas; `series_id` y `tipo` le dicen de qué serie viene cada una;
- sin `groupby` aparecen filas falsas: B 10:00 con $y_{t-1} = 60$ y A 14:00 con target 400 (**mezcla de historias**);
- B está en otra escala (unas 8 veces A): sin escalar por serie, sus errores dominan la pérdida.

Validar un modelo global

El mismo protocolo temporal, aplicado a todas las series a la vez

- walk-forward con el **mismo corte temporal** T_k para todas las series;
- nunca usar el futuro de una serie para predecir el pasado de otra;
- el embargo g se aplica igual en todas;
- métricas **por serie** y agregadas (sección de métricas);
- comparar contra modelos locales y contra el seasonal naïve de cada serie.

Leakage específico del modelo global

Escalar cada serie con su media de **toda** la historia filtra el nivel futuro. La escala se calcula solo con el train de cada fold.

**Antes del modelo: demostrar que el
pasado simple no basta**

Tres referencias temporales obligatorias

Un baseline temporal no es un modelo ridículo

- **Naïve** $\hat{y}_{t+h} = y_t$: aprovecha la **persistencia**;

- **Seasonal naïve**

$\hat{y}_{t+h} = y_{t+h-s}$ ($s = 24$ en datos horarios): aprovecha el **ciclo**;

- **Moving average**

$\hat{y}_{t+h} = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$: robusto con ruido local.



Criterio de clase

Un modelo temporal sofisticado que no supera un baseline temporal honesto no merece una defensa fuerte.

Cuándo cada baseline pone presión real

El baseline correcto depende de la estructura temporal dominante

Baseline	Es fuerte cuando...	Puede fallar cuando...
Naïve	la serie tiene alta persistencia y cambia lentamente	hay cambios bruscos o ciclos fuertes
Seasonal naïve	existe patrón diario, semanal o mensual estable	el ciclo cambia por eventos, clima o régimen
Moving average	el nivel reciente resume bien el estado operativo	suaviza demasiado picos o eventos raros

Taller / tarea: **Práctica**

¿Qué baseline usaría primero para: tráfico 1 hora adelante; demanda energética mañana a la misma hora; ventas diarias con fines de semana? En un modelo global, el baseline se calcula **por serie**.

Validación temporal: random split, walk-forward y leakage

Random split puede ser una trampa temporal

El futuro no debe entrenar el modelo que evalúa el pasado

$$\exists t_i \in D_{\text{train}}, \exists t_j \in D_{\text{val}} \text{ tal que } t_i > t_j$$

Esquema	Qué hace	Riesgo o utilidad
Random split	mezcla observaciones de distintos momentos	infla el desempeño si hay dependencia temporal
Temporal holdout	entrena en pasado y valida en un bloque futuro	simple, útil y más cercano a operación real
Walk-forward	repite la evaluación avanzando en el tiempo	estima desempeño de forma más robusta

Regla


El score puede subir no porque el modelo sea mejor, sino porque el experimento fue más fácil. El split debe responder: ¿cómo habría funcionado el modelo si se hubiera usado en ese momento?

Validar hacia adelante

Entrenar con pasado, validar en futuro y repetir

- el modelo se entrena con historia disponible;
- predice un bloque futuro;
- el origen de predicción avanza;
- el desempeño se resume sobre varios bloques.

La validación temporal pregunta: ¿qué habría pasado si el modelo se hubiera usado en ese momento?



La restricción cronológica y el score final

Cada validación debe estar después de su entrenamiento

$$D_{\text{train}}^{(k)} = \{(X_t, y_{t+h}) : t \leq T_k\} \quad D_{\text{val}}^{(k)} = \{(X_t, y_{t+h}) : T_k < t \leq T_{k+1}\}$$

$$\max(t \in D_{\text{train}}^{(k)}) < \min(t \in D_{\text{val}}^{(k)}) \quad \hat{E}_{\text{WF}} = \frac{1}{K} \sum_{k=1}^K E(D_{\text{val}}^{(k)})$$

- en cada fold, el entrenamiento termina antes de que empiece la validación;
- K : número de cortes; $E(D_{\text{val}}^{(k)})$: error del fold k en un bloque futuro;
- el score final promedia varios futuros evaluados, no una medición aislada (reporte también la dispersión).

Variantes útiles de validación temporal

La decisión depende de historia disponible, estabilidad y costo computacional

Esquema	Cómo entrena	Cuándo tiene sentido
Holdout temporal	un bloque pasado para train y un bloque futuro para validación	primera comparación simple y clara
Ventana expansiva	cada fold acumula más historia antes de validar el siguiente bloque	cuando más historia suele aportar señal útil
Ventana deslizante	cada fold usa solo una ventana reciente de longitud fija	cuando los patrones antiguos dejan de representar el presente

No existe una única validación temporal universal: debe corresponder al uso real, al horizonte y a la estabilidad del fenómeno.

Embargo: una separación cuando hay riesgo de vecindad

No todo fold cronológico queda automáticamente limpio

$$\max(t_{\text{train}}) + g < \min(t_{\text{val}})$$

- g : tamaño de la brecha temporal;
- $g = 24$ en datos horarios deja un día de separación;
- útil si las features usan ventanas largas o labels futuros;
- no reemplaza una mala formulación.

```
from sklearn.model_selection import  
    TimeSeriesSplit  
tscv = TimeSeriesSplit(n_splits=5,  
                        test_size=24 * 28,  
                        gap=24)    # embargo
```

Es la CV temporal de la S1, ahora con embargo.

Práctica: diseño el protocolo

El split debe ser una decisión defendible, no una línea de código por costumbre

Taller / tarea: **Escenario**

Datos horarios de tráfico entre 2012 y 2018. Quiere predecir una hora adelante y comparar seasonal naïve, Ridge e HistGradientBoostingRegressor.

Defina:

1. tamaño del bloque inicial de entrenamiento y del bloque de validación;
2. ventana expansiva o deslizante, y si necesita embargo;
3. qué métrica reportaría por fold y cómo resumiría el desempeño final;
4. cómo cambia el protocolo si son 20 clientes de electricidad (modelo global).

Leakage temporal: la regla formal

La pregunta no es "¿la columna existe?", sino "¿el sistema la conocía antes de predecir?"

$x_j(t) \in \mathcal{I}_t \implies x_j(t)$ es candidata válida

$x_j(t) \notin \mathcal{I}_t \implies x_j(t)$ introduce riesgo de leakage

Definición: $\mathcal{I}_t$

Conjunto de información que el sistema podía conocer antes o en el momento operativo de predicción t .

El leakage puede entrar por features que miran hacia adelante, preprocessing ajustado con toda la serie, variables externas publicadas tarde o folds que mezclan futuro y pasado.

Rutas comunes de leakage temporal

El futuro puede entrar por features, preprocessing o validación

Ruta	Qué parece hacer	Por qué contamina
Rolling mal alineado	calcula una media móvil suave	incluye y_t , y_{t+1} o valores posteriores
Escalamiento global	normaliza todas las filas antes del split	aprende estadísticas del futuro
Escala por serie con toda la historia	normaliza cada serie del modelo global	filtra el nivel futuro de cada serie
Variable externa tardía	agrega clima o evento observado después	la señal no existía al decidir
Folds mezclados	valida en pasado y entrena con futuro	rompe la dirección operacional

Taller / tarea: **Práctica: audite**

¿Qué falla en: `rolling_mean24` con ventana centrada; `StandardScaler` ajustado con todo el histórico; features elegidas mirando el bloque de test?

**Medir error no basta: hay que
interpretarlo contra tiempo y baseline**

MAE y RMSE: dos lecturas del error

El error se lee contra un baseline y un horizonte

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- en unidades del target;
- fácil de comunicar;
- resume el error típico absoluto.

- castiga más los errores grandes;
- sensible a picos;
- útil si los desvíos extremos son costosos.

Cuidado

Un MAE aparentemente bajo puede ser mediocre si el seasonal naïve logra lo mismo con una regla simple.

MASE: escalar el error con una referencia temporal

La pregunta es: ¿mejoro una predicción naïve?

$$\text{MASE} = \frac{\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|}{\frac{1}{T_{\text{train}} - m} \sum_{t=m+1}^{T_{\text{train}}} |y_t - y_{t-m}|}$$

- numerador: error absoluto medio del modelo;
- denominador: error del naïve ($m = 1$) o del seasonal naïve ($m = 24$) **en train**;
- no depende de la escala: sirve para comparar series.

Valor	Interpretación
< 1	mejora al baseline
≈ 1	similar al baseline
> 1	peor que el baseline

MAPE, sMAPE y WAPE: alternativas con cautela

El porcentaje parece intuitivo y aun así puede engañar

- **MAPE** divide por el valor real: si es bajo o cercano a cero, explota;
- **sMAPE** lo simetriza dividiendo por el promedio de real y predicción, pero sigue siendo inestable cerca de cero:

$$\text{sMAPE} = \frac{1}{n} \sum_i \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

- **WAPE** divide el error total por el volumen total:

$$\text{WAPE} = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|}$$

Taller / tarea: Práctica

¿Qué métrica principal para: tráfico (error típico en vehículos), energía (errores extremos costosos), inventario (superar al naïve)?

Regla de la sesión

MAE, RMSE y MASE son centrales; WAPE para agregados con ceros.

Métricas para muchas series

Un modelo global se evalúa por serie y en conjunto

Métrica	Cómo se calcula	Qué pregunta responde
MAE promedio	MAE de cada serie y su media	engañosa: las series grandes dominan
MASE promedio	MASE de cada serie (escala propia) y su media	¿el modelo mejora al naïve en una serie típica?
WAPE agregado	error total / volumen total de todas las series	¿cuánto volumen total se predice mal?
RMSSE	raíz del error cuadrático escalado por el naïve (M5)	como MASE, pero castiga errores grandes

Idea clave: **Lectura**

No se promedian errores de series con escalas distintas sin escalarlos primero. Reporte también cuántas series mejoran al baseline.


Un modelo no tiene un único desempeño temporal

El error debe indexarse por la distancia al futuro

$$\hat{y}_{t+h} = f_h(X_t) \quad h \in \{1, 3, 6, 24\}$$

$$E_h = \frac{1}{n_h} \sum_{i=1}^{n_h} L(y_{t_i+h}, \hat{y}_{t_i+h})$$

- horizonte corto: domina el estado reciente y los lags cercanos;
- horizonte largo: más incertidumbre; dominan ciclos y calendario.



Cómo cambia la utilidad por horizonte

La métrica debe leerse con la decisión que habilita

Horizonte	Señal que suele dominar	Decisión que puede soportar
1 hora	estado reciente, lag_1 , tendencia local	gestión inmediata de congestión o alertas
6 horas	ciclos diarios parciales y contexto externo	anticipación de carga en media jornada
24 horas	estacionalidad diaria, calendario, patrones recurrentes	planeación del día siguiente

Taller / tarea: Práctica

El modelo A gana en MAE a 1 hora; el B es más estable a 6 y 24 horas. El equipo necesita planear el día siguiente: ¿cuál defiende y qué baseline debe aparecer?

**El modelo entra cuando el
experimento ya es defendible**

Primero formulación, después complejidad

Los modelos compiten contra baselines bajo el mismo protocolo temporal

Antes del modelo

- target y horizonte;
- features válidas;
- baselines temporales;
- walk-forward.


Modelo	Papel
Ridge	referencia supervisada lineal, fácil de explicar
HistGradientBoosting HGBR o LightGBM global	no linealidad e interacciones (Metro) un solo modelo para muchas series (Electricity)

Después del modelo

Si el modelo gana, debe ganar contra una referencia honesta, sin leakage y en el horizonte que importa.

Familias de modelos temporales

De más supuestos a más flexibilidad, bajo la misma validación



- **clásicos** (ARIMA, SARIMA, SARIMAX): pocos parámetros, una serie a la vez, estructura explícita;
- **ML tabular**: la memoria entra como features (lags, rolling, calendario); escala a modelos globales;
- todos se comparan con el mismo target, horizonte, baseline y walk-forward.

ARIMA(p, d, q): valores, cambios y errores pasados


Un modelo lineal sobre la propia historia de la serie

Sobre la serie diferenciada $y'_t = \nabla^d y_t$:

$$y'_t = c + \underbrace{\sum_{i=1}^p \phi_i y'_{t-i}}_{\text{AR: valores}} + \underbrace{\sum_{j=1}^q \theta_j \varepsilon_{t-j}}_{\text{MA: errores}} + \varepsilon_t$$

- p : lags de la serie (orienta la PACF);
- d : diferencias para quitar tendencia;
- q : errores pasados que corrigen (orienta la ACF).

Conexión: la parte AR es una regresión lineal sobre lags, como Ridge con $\text{lag}_1, \dots, \text{lag}_p$.



SARIMA y SARIMAX: ciclo y variables externas

SARIMA(p, d, q)(P, D, Q) $_s$ y la versión con exógenas

SARIMA: agrega el ciclo

- (P, D, Q) repiten la idea de ARIMA con lags **estacionales** $y_{t-s}, y_{t-2s}, \dots$;
- s : periodo del ciclo ($s = 24$ en datos horarios con ciclo diario);
- ejemplo: $(1, 0, 1)(1, 1, 1)_{24}$ usa la hora anterior y la misma hora de ayer.

SARIMAX: agrega exógenas

$$y_t = \beta^\top x_t + \text{SARIMA}(\dots)$$

- x_t : clima, festivos, precio, promociones;
- para predecir $t + h$ se necesita x_{t+h} : solo vale si se **conoce** (festivo) o se usa su **pronóstico** (clima).

Leakage en SARIMAX

Usar el clima **observado** de mañana en lugar del pronosticado da un score que en producción no existe.

Clásico frente a ML tabular

Cuándo probar cada uno

	ARIMA / SARIMA(X)	ML tabular (HGBR, LightGBM)
Memoria	órdenes p, q, P, Q	lags y rolling como columnas
Estacionalidad	$(P, D, Q)_s$, un solo periodo	calendario, Fourier, varios ciclos a la vez
Exógenas	lineales $(\beta^\top x_t)$	no lineales e interacciones
Muchas series	un modelo por serie (local)	un modelo global
Datos	funciona con historias cortas	necesita más filas
Salida	intervalos de predicción nativos	puntual (intervalos con quantile loss)

En statsmodels: `SARIMAX(y, exog=X, order=(p,d,q), seasonal_order=(P,D,Q,s))`. Se evalúa con el **mismo** walk-forward y MASE que el resto.

El notebook ejecuta el contrato metodológico

Pseudocódigo y qué debe inspeccionarse

```
1 # 1. Ordenar por tiempo (y por serie)
2 # 2. Target futuro: y.shift(-h)
3 # 3. Lags: y.shift(k) por serie
4 # 4. Rolling: y.shift(1).rolling(w)
5 # 5. Split cronológico + embargo
6 # 6. Preprocessing solo en train
7 # 7. Métricas por fold y horizonte
```

Salida	Pregunta
Dummy manual	¿se ve la alineación lag-target?
Serie sintética	¿random split infla el score?
Baselines	¿el modelo los supera?
Walk-forward	¿es estable entre folds?
Multi-horizonte	¿cómo se degrada el error?
Global vs local	¿mejoran MASE y WAPE por serie?

La historia aplicada de la demo

El resultado cambia cuando cambia el protocolo de validación

Componente	Decisión
Target	volumen de tráfico futuro
Horizontes	$h = 1$; también 3, 6, 24
Features	lags, rolling, calendario, clima disponible
Baselines	naïve, seasonal naïve, MA
Modelos	Ridge e HGBR
Validación	holdout temporal y walk-forward

La demo debe mostrar

1. random split como anti-ejemplo;
2. holdout temporal como primera corrección;
3. walk-forward como evaluación operacional;
4. baselines antes de modelos;
5. error por horizonte antes de concluir.

Hands-on de la sesión

Los tres ejercicios del syllabus

1. **Modelo global:** un HGBR o LightGBM para 20 clientes de electricidad frente a modelos locales y al seasonal naïve de cada serie (MASE y WAPE por serie).
2. **Walk-forward:** protocolo con ventana expansiva y embargo sobre Metro; dispersión del error entre folds.
3. **Comparar horizontes:** MAE y MASE para $h \in \{1, 3, 6, 24\}$; ¿dónde gana cada modelo?

Herramienta: **Notebook**

[03_ml_time_series_walkforward.ipynb](#) (local con uv o en Colab) · sección de modelo global: **[por publicar]**

Checklist temporal y cierre metodológico

Un resultado temporal defendible es una cadena

Si falta un eslabón, el score pierde credibilidad

Evidencia fuerte

- target y horizonte explícitos;
- features disponibles en t ;
- baseline temporal superado;
- walk-forward sin contaminación;
- error reportado por horizonte.

Evidencia frágil

- random split sin justificación;
- rolling windows mal alineadas;
- preprocessing antes del split;
- un único score para todos los horizontes.

Idea clave: Lo que debe quedar claro

Si el problema tiene tiempo, el futuro no puede ayudar a entrenar, transformar, seleccionar o validar el pasado.

Glosario

Términos que deben usarse con precisión

Término	Interpretación operativa
Momento t / horizonte h	instante de decisión / distancia al target futuro
Lag / rolling window	memoria puntual / resumen de una ventana que mira solo hacia atrás
Ventana deslizante	fila formada por los últimos L valores y un objetivo h pasos adelante
Directa / recursiva	un modelo por horizonte / un modelo a 1 paso que se realimenta
Fourier	pares seno/coseno para estacionalidades largas
Modelo global	un modelo entrenado con muchas series a la vez
Walk-forward / embargo	validación que avanza en el tiempo / brecha g entre train y validación
MASE / WAPE / RMSSE	error relativo al naïve / error total sobre volumen / MASE cuadrático

(Opcional) Estabilidad y diferenciación

Cuándo el pasado representa el futuro y cómo trabajar con cambios

$$\nabla y_t = y_t - y_{t-1}$$

$$\nabla_s y_t = y_t - y_{t-s}$$

Estacionariedad (criterio práctico)

- ¿pasado y futuro tienen una estructura comparable?
- si la media cambia mucho, el pasado representa mal el futuro;
- no se asume: se inspecciona y se valida hacia adelante.

Diferenciación

- regular: reduce tendencia (d en ARIMA);
- estacional: reduce ciclos repetidos (D en SARIMA);
- el modelo aprende variaciones, no valores absolutos.

Preguntas de revisión para examen, taller y PI

La evaluación buscará decisiones correctas, no trivia de librerías

1. ¿Cuál es el target temporal y el horizonte?
2. ¿Qué features existían en el momento t ?
3. ¿Qué baseline temporal debe ser superado?
4. ¿Qué split respeta la cronología?
¿Necesita embargo?
5. ¿Dónde podría entrar leakage antes del modelo?
6. ¿Directa o recursiva para 24 pasos?
7. ¿Cuándo un modelo global en vez de uno por serie?
8. ¿Por qué no promediar MAE entre series?
9. ¿El error se reporta por horizonte?

En el taller: el código que corre no basta; la evaluación debe sostener una decisión.

Transición a la siguiente sesión

Después del tiempo aparecen usuarios, ítems, interacciones y rankings

Hoy rompimos la idea de que las filas son intercambiables cuando existe tiempo.

En la próxima sesión, romperemos otra intuición: no siempre queremos predecir un único valor, a veces queremos ordenar opciones para una persona.

Idea clave: Sesión 4

Recomendadores (matriz de utilidad, feedback implícito, ALS, híbridos) e interpretabilidad con SHAP.

Gracias por su atención

¿Preguntas, comentarios o discusión?



Aprendizaje Automático
SI7009 · Universidad EAFIT

