


Clustering, anomalías y confiabilidad

Aprendizaje Automático · Sesión 6



Andrés Vásquez Restrepo

avasquezr3@eafit.edu.co

SI7009 - 1 (5553)

Universidad EAFIT

2026-2 – Medellín

Contenido

1. Formular el clustering
2. K - Means y Mini - Batch K - Means
3. Clustering jerárquico
4. DBSCAN y HDBSCAN
5. Validar sin etiquetas
6. Segmentación accionable
7. Outliers: Isolation Forest y LOF
8. Confiabilidad: drift y calibración
9. Cierre del curso

Dónde quedamos

Ayer (S5)

- 1.740 vendedores de Olist, 8 variables, log + escalado;
- PCA: tamaño (PC1) y mala entrega (PC2);
- t-SNE y UMAP: vecindarios, no distancias globales.

Hoy

- proponer **grupos** en ese espacio y decidir si sirven;
- lo que no encaja (outliers) y lo que cambia (drift).

Idea clave: **Taller, Módulo C**

Entrega 17/10. K-Means + otra familia, codo, silueta, Davies-Bouldin, ARI entre semillas y perfiles con acción. Todo eso aparece hoy, con vendedores en lugar de clientes.

Formular el clustering

Un cluster no es un segmento

Definición: Cluster

Lo que entrega el algoritmo: una partición de los datos que optimiza un criterio geométrico.

Cualquier algoritmo con $k = 4$ devuelve 4 grupos, **haya o no estructura**.

Siempre hay clusters. No siempre hay segmentos.

Definición: Segmento

Un grupo que el negocio puede usar. Debe ser:

- **nombrable**: se describe en una frase;
- **estable**: sobrevive a otra semilla o muestra;
- **accionable**: pide una acción distinta;
- **de tamaño útil**: ni el 85 % ni 12 casos.

La distancia define los grupos

El clustering agrupa lo que está **cerca**. Quien decide qué es "cerca" es usted:

Qué variables

Con solo ventas y órdenes, los grupos serán "grandes" y "pequeños". Con retraso y calificación aparece la experiencia de entrega.

Qué escala

Sin log ni escalado, ventas (hasta 500.000 BRL) decide sola (S5).

Variable casi constante

En Olist la gran mayoría de los clientes compra **una sola vez**: la frecuencia vale 1 para casi todos y no separa a nadie. Tras escalar, sus pocos valores distintos de 1 quedan como outliers.

Idea clave

Opciones: binarizar (1 frente a ≥ 2), sacarla del clustering o usarla solo para perfilar.

Cuatro familias

Familia	Ejemplos	Qué supone	Dónde falla
Centroides	K - Means, Mini - Batch	grupos convexos, de tamaño y varianza parecidos	formas alargadas o curvas; outliers
Jerárquica	aglomerativo (Ward, average, single)	depende del linkage	n grande (memoria $O(n^2)$)
Densidad	DBSCAN, HDBSCAN	grupos = zonas densas separadas por zonas ralas	datos sin zonas ralas; muchas dimensiones
Modelos	GMM	mezcla de gaussianas	solo mención hoy

Idea clave

Cada familia trae su propia idea de "grupo". Elegir el algoritmo es elegir esa idea.

K - Means

El objetivo

Dado k , buscar centroides $\mu_1, \dots, \mu_k$ y asignaciones $C_1, \dots, C_k$ que minimicen la **inercia**:

$$J = \sum_{c=1}^k \sum_{i \in C_c} \|x_i - \mu_c\|^2$$

Definición: Algoritmo de Lloyd


Repetir hasta que nada cambie:

1. **asignar**: cada punto al centroide más cercano;
2. **actualizar**: cada centroide = media de sus puntos.


Garantías

Cada paso baja J (o la deja igual), así que converge. Pero encontrar el mínimo global es NP-hard: Lloyd llega a un **mínimo local** que depende del inicio.

Lloyd a mano: el mini-mundo



inicio: centroides en A y B



final: $J = 6,67$

Iter.	Asignar	Actualizar
1	$\{A, C, E\} / \{B, D, F\}$	$\mu_1 = (3,33; 4,00),$ $\mu_2 = (5,33; 4,00)$
2	$\{A, B, C\} / \{D, E, F\}$	$\mu_1 = (1,67; 2,00),$ $\mu_2 = (7,00; 6,00)$
3	sin cambios	converge


Aun empezando con los dos centroides en el mismo grupo, Lloyd se recupera porque los grupos están muy separados. Con datos reales no siempre pasa.

Idea clave


Ejercicio: verifique J a mano. (Cada grupo aporta 3,33.)

Iniciación: k-means++

init aleatoria, peor de 200 semillas
inercia = 1726



k-means++, n_init=10
inercia = 417



Definición: k-means++

Primer centroide al azar; cada siguiente con probabilidad $\propto D(x)^2$, la distancia al centroide más cercano ya elegido. Los inicios quedan repartidos.


- con inicio aleatorio, el 8,5 % de 200 semillas termina con inercia más de 5 % peor;
- n_init=10: corre 10 veces y se queda con la menor inercia.

Supuestos y fallos


lunas (no convexos)



anisotrópicos




tamaños muy distintos



K-Means corta el espacio en celdas de Voronoi: fronteras **rectas** a mitad de camino entre centroides. Supone grupos convexos, de varianza y tamaño parecidos.

Con lunas, grupos alargados o tamaños muy distintos, K-Means da una partición limpia... y equivocada.

Elegir k : el codo



- la inercia **siempre** baja con k : con $k = n$ vale 0;
- se busca el punto donde agregar un grupo deja de ayudar mucho;
- en los vendedores de Olist no hay un codo nítido (lo normal con datos reales).

Idea clave

El codo es una pista, no una regla: se combina con silueta, DB, estabilidad y negocio.

Mini-Batch K-Means

Definición: Idea

En cada paso usar un **lote** aleatorio de b puntos (p. ej. 1.024 o 4.096) en lugar de todos los datos.

Para cada x del lote, con centroide asignado c :

$$n_c \leftarrow n_c + 1, \quad \eta = \frac{1}{n_c}, \quad \mu_c \leftarrow (1 - \eta) \mu_c + \eta x$$

El paso η se achica a medida que el centroide acumula puntos: es un promedio móvil, como un descenso de gradiente estocástico.

Costo por iteración



K-Means: $O(n k p)$

Mini-Batch: $O(b k p)$, con $b \ll n$

Datos que no caben en memoria

`partial_fit` recibe los datos por bloques o en flujo.

K-Means frente a Mini-Batch




- en una laptop, el K-Means de scikit-learn (Elkan/Lloyd en paralelo) es **más rápido** aquí hasta 10^6 filas;
- Mini-Batch pierde entre 0 y 3 % de inercia.

Idea clave: **Cuándo usarlo**

Datos que no caben en memoria, que llegan en flujo, o n de decenas de millones. No “porque es más rápido”: mídalo.

Clustering jerárquico

Aglomerativo



1. cada punto empieza como su propio cluster;
2. fusionar los dos clusters más cercanos;
3. repetir hasta que quede uno.

Paso	Fusión (single linkage)	Distancia
1-3	A con B, A con C, E con F	1,41
4	D con {E, F}	2,24
5	{A, B, C} con {D, E, F}	4,47

El resultado no es una partición: es un **árbol** de particiones anidadas.

Linkage: distancia entre grupos


Linkage	Distancia entre G y H	Efecto
Single	$\min_{i \in G, j \in H} d(i, j)$	encadena: un puente de puntos une dos grupos
Complete	$\max_{i \in G, j \in H} d(i, j)$	grupos compactos; sensible a outliers
Average	promedio de $d(i, j)$ entre todos los pares	término medio
Ward	aumento de la inercia al fusionar G y H	grupos esféricos de tamaño parecido: el más cercano a K-Means

Idea clave

Ward es la opción por defecto para segmentar con variables numéricas escaladas. Single solo si espera grupos con formas alargadas y sin ruido.

Leer y cortar el dendrograma

Dendrograma: 300 vendedores de Olist



- altura de cada unión = disimilitud a la que se fusionaron esos grupos;
- cortar con una línea horizontal da una partición; un **salto grande** de altura sugiere dónde cortar;
- aquí: 300 vendedores, Ward, corte en 4 grupos.

Costo y uso práctico

Costo

Matriz de distancias: memoria $O(n^2)$.

- 1.740 vendedores: 1,5 millones de pares, sin problema;
- 96.000 clientes de Olist: 4.600 millones de pares, **no cabe**.

Salidas: muestra aleatoria, connectivity (solo vecinos), o K-Means con muchos grupos y luego jerárquico sobre los centroides.


Idea clave: Para qué sirve

Ver la **jerarquía** de segmentos: un grupo grande que se divide en dos subgrupos con acciones distintas. Y elegir k mirando las alturas.

Las fusiones son definitivas: un error temprano no se corrige después.

Clustering por densidad

DBSCAN



$$\text{eps} = 2,3 \cdot \text{min_samples} = 3$$

Dos parámetros: radio eps y min_samples .


- **núcleo:** tiene al menos min_samples puntos (contándose) a distancia $\leq \text{eps}$;
- **borde:** no es núcleo, pero está a $\leq \text{eps}$ de un núcleo;
- **ruido:** ninguna de las dos (etiqueta -1).

Un cluster = núcleos conectados entre sí más sus bordes.

Mini-mundo + G(5, 1)

A–F son núcleo (2 vecinos a $\leq 2,4$). El vecino más cercano de G está a 3,0: **ruido**. Dos clusters, sin perder k .

Elegir eps




1. para cada punto, distancia a su k -ésimo vecino ($k = \text{min_samples}$);
2. ordenar de menor a mayor;
3. eps cerca del codo: a la derecha están los puntos que quedarían como ruido.

Limitación

Un solo eps supone **una sola densidad**. Si hay grupos densos y grupos ralos, ningún valor sirve para todos.

HDBSCAN

DBSCAN eps=0.2
3 cluster(s), 50% ruido



DBSCAN eps=0.6
1 cluster(s), 7% ruido



HDBSCAN min_cluster_size=25
2 clusters, 23% ruido



1. distancia de alcanzabilidad mutua:
 $\max\{\text{core}_k(a), \text{core}_k(b), d(a, b)\};$
2. árbol de expansión mínima $\rightarrow$ jerarquía para **todos** los eps;
3. se conservan los clusters que persisten en un rango amplio de densidades.

En la práctica

Un parámetro principal:
`min_cluster_size`.
Entrega `probabilities_` (fuerza de pertenencia).
En `sklearn.cluster.HDBSCAN`.

El ruido es un resultado

Idea clave

La etiqueta -1 no es un error del algoritmo. Dice: "estos puntos no pertenecen claramente a ningún grupo".

Qué pueden ser:


- outliers reales (sección 7);
- casos "no segmentables" que merecen tratamiento genérico;
- señal de que `min_cluster_size` es muy grande.

Reporte siempre

- qué porcentaje es ruido;
- cómo cambia con los parámetros;
- qué se hará con esos casos en producción.

Un 40 % de ruido no es "4 segmentos": es 4 segmentos **más** un grupo enorme sin segmentar.

Cuatro algoritmos, mismos datos



- **blobs**: todos aciertan;
- **lunas**: solo los de densidad;
- **anisotrópico**: nadie perfecto; HDBSCAN marca como ruido la zona ambigua;
- **densidad variable**: K-Means y Ward aciertan; DBSCAN con un solo eps deja ruido en el grupo raro.

Idea clave

No hay ganador universal. Compare al menos dos familias.

Gris = ruido.

Validar sin etiquetas

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1]$$

- $a(i)$: distancia media de i a su propio cluster (cohesión);
- $b(i)$: distancia media al cluster vecino más cercano (separación);
- cerca de 1: bien asignado; cerca de 0: en la frontera; negativo: mal asignado.

Mini-mundo, punto A


$$a(A) = \frac{1,41+1,41}{2} = 1,41$$

$$b(A) = \frac{5,83+7,81+8,06}{3} = 7,23$$

$$s(A) = \frac{7,23-1,41}{7,23} = 0,80$$

La silueta global es el promedio de $s(i)$.

El gráfico de silueta



- una barra por punto, agrupadas por cluster;
- grosor = tamaño del cluster;
- valores negativos = puntos que estarían mejor en otro grupo.

Idea clave: **Vendedores de Olist**

Silueta media 0,20: los grupos existen pero se tocan. Es lo habitual con comportamiento de clientes o vendedores: más un continuo que islas.

Davies–Bouldin y Calinski–Harabasz

Métrica	Fórmula	Mejor	Ojo
Silueta	promedio de $\frac{b(i)-a(i)}{\max(a,b)}$	mayor	costo $O(n^2)$
Davies–Bouldin	$\frac{1}{k} \sum_c \max_{c' \neq c} \frac{s_c + s_{c'}}{d(\mu_c, \mu_{c'})}$	menor	usa centroides
Calinski–Harabasz	$\frac{\text{tr}(B)/(k-1)}{\text{tr}(W)/(n-k)}$	mayor	crece con grupos esféricos


s_c : distancia media de los puntos de c a su centroide. B, W : dispersión entre y dentro de grupos.

Idea clave

Las tres miden lo mismo con otra fórmula: grupos compactos y separados. Ninguna mide si el grupo sirve.

Las métricas internas prefieren esferas

K-Means: silueta = 0.49



DBSCAN: silueta = 0.39




- DBSCAN encuentra las dos lunas;
- K-Means las corta mal...
- ... y aun así tiene **mejor silueta** (0,50 frente a 0,39).

Silueta, DB y CH asumen grupos compactos. No compare con ellas algoritmos de familias distintas sin mirar los datos.

Con ruido: calcule la métrica sin los -1 y reporte el % de ruido aparte.

Estabilidad: ARI



1. tomar submuestras del 80 % (o cambiar la semilla);
2. reajustar y comparar con la partición completa;
3. *Adjusted Rand Index*: 1 = mismas particiones, 0 = coincidencia al azar.

Definición: **Stability index**

ARI medio entre réplicas (Ben-Hur et al., 2002; Lange et al., 2004). Un k que no se repite no describe los datos.

`sklearn.metrics.adjusted_rand_score`

Decidir k con evidencia

k	Inercia	Silueta $\uparrow$	DB $\downarrow$	CH $\uparrow$	ARI medio $\uparrow$	Grupo más chico
2	11.244	0,185	1,88	414	0,97	47 %
3	9.533	0,202	1,59	400	0,87	18 %
4	8.319	0,177	1,53	390	0,88	12 %
5	7.639	0,174	1,56	357	0,85	11 %
6	7.138	0,157	1,56	330	0,89	10 %
7	6.720	0,164	1,58	309	0,88	8 %
8	6.396	0,169	1,55	291	0,80	5 %


Las métricas **no coinciden**. $k = 2$ es el más estable pero dice poco; $k = 3$ y $k = 4$ quedan casi empatados.

Idea clave: **Elección:** $k = 3$

Mejor silueta y CH (salvo $k = 2$), ARI 0,87, ningún grupo < 15 % y tres acciones distintas. Con $k = 4$ habría que mostrar que el cuarto grupo pide otra acción.

De cluster a segmento

El pipeline completo




Con qué datos

Features con información hasta la fecha de corte (aquí 2018-06-01). Para asignar vendedores nuevos: predict del mismo pipeline, sin re-ajustar.

Las proyecciones 2D

t-SNE y UMAP en 2D sirven para **mirar** los grupos. No se agrupa sobre ellas (S5).

Perfilamiento



Mediana de cada variable por grupo. Color: cuántas veces la mediana del grupo supera (naranja) o queda por debajo (azul) de la mediana global. Se perfila en las **variables originales**, no en las escaladas.

Nombrar y actuar

Segmento	Evidencia (mediana)	Acción
C0 · Grandes y diversificados (735)	43 órdenes, 5,9 k BRL, 3 categorías, 7 % de retraso	cuenta clave: soporte dedicado, prioridad en campañas
C1 · Con problemas de entrega (318)	25 % de retraso, 3,6 días hasta la transportadora, calificación 3,65	plan logístico, alertas de despacho, seguimiento de reseñas
C2 · Pequeños de ticket bajo (687)	ticket 74 BRL, flete = 27 % del precio, 0 % de retraso, calificación 4,39	subsidio o consolidación de flete; incentivos para crecer

Idea clave

Cada nombre debe poder leerse en la tabla de perfiles. Si dos segmentos terminan con la misma acción, para el negocio son uno solo.

Práctica: ¿aprobaría esta segmentación?

Taller / tarea: **Situación**

Un equipo presenta 5 segmentos de clientes con silueta 0,55. En el anexo: ARI medio entre semillas 0,40, y un segmento tiene el 85 % de los clientes. Las otras cuatro campañas apuntan al 15 % restante.

Discuta en parejas (3 minutos):

- ¿la silueta alta compensa el ARI bajo?
- ¿qué dice un grupo con el 85 %?
- ¿qué pediría antes de aprobar?

Idea clave: **Respuesta esperada**

No se aprueba. ARI 0,40 = otra semilla da otros segmentos. El 85 % sugiere que la silueta alta viene de separar unos pocos casos raros (¿outliers?). Pedir: estabilidad, perfiles y otra familia de algoritmos.

Anti-patrones

1. elegir k solo por silueta (o solo por el codo);
2. agrupar sobre t-SNE o UMAP en 2D;
3. no escalar, o escalar sin transformar las sesgadas;
4. no probar otras semillas ni submuestras;
5. segmentos sin una acción distinta;
6. un grupo gigante y varios diminutos;
7. perfilar en variables escaladas ("z = 1,3" no le dice nada a nadie).


Cualquiera de estos invalida una segmentación aunque las métricas se vean bien.

Idea clave: Taller

La rúbrica del Módulo C evalúa estabilidad y perfilamiento accionable, no solo el número de grupos.

Lo que no encaja: outliers

Isolation Forest



G queda aislado con 2 cortes

- árboles con cortes **aleatorios** (variable al azar, umbral al azar);
- un punto raro queda solo en una hoja con **pocos** cortes; uno normal necesita muchos;
- score con la profundidad media $E[h(x)]$ en el bosque:

$$s(x) = 2^{-E[h(x)]/c(n)}$$


$c(n)$: profundidad media esperada. $s \rightarrow 1$: anómalo;
 $s \approx 0,5$: normal.

Parámetro clave


contamination: qué fracción se marca como anómala. Es una decisión de negocio.

Local Outlier Factor

Isolation Forest: 6 puntos más anómalos



LOF: 6 puntos más anómalos



LOF compara la densidad local de un punto con la de sus k vecinos:

- $LOF \approx 1$: tan denso como su vecindario;
- $LOF \gg 1$: mucho más aislado que sus vecinos.

El punto (1,2; 1,2) está cerca del grupo denso: $LOF = 3,5$ (anómalo); para Isolation Forest es el nº 30 de 403.

Idea clave

IF: raro respecto a **todos**. LOF: raro respecto a **sus vecinos**.

Práctica: el 1 % más raro

Con `contamination=0.01` sobre los 1.740 vendedores:

- Isolation Forest marca 18, LOF marca 18;
- solo **7** aparecen en ambos;
- mediana de los marcados por IF: 53 % de retraso, 9,1 días hasta la transportadora, flete = 50 % del precio, calificación 2,67.

Taller / tarea: ¿Qué hace con ellos?

Para cada uno decida: ¿error de datos?, ¿vendedor con problemas operativos?, ¿fraude?, ¿vendedor excepcional?

Un outlier se investiga antes de borrarlo. Muchas veces es el caso más importante del dataset.


Cuando el mundo cambia

Tipos de drift



Tipo	Qué cambia	En Olist
Covariate	$P(X)$	más órdenes de otras regiones, otro mix de categorías
Prior	$P(y)$	la tasa de retraso pasa de 3 % a 21 % (mar. 2018)
Concepto	$P(y X)$	la misma distancia y peso ya no implican el mismo riesgo
Predicción	$P(\hat{y})$	el modelo del Módulo A dispara el triple de alertas
Segmentos	tamaños, centroides	vendedores que migran de C2 a C1

Detectarlo: PSI y KS



$$PSI = \sum_b (a_b - e_b) \ln \frac{a_b}{e_b}$$

e_b , a_b : proporción en el bin b en la referencia y en el periodo actual. Regla usual: $< 0,1$ estable; $0,1-0,25$ vigilar; $> 0,25$ cambio fuerte.

- días de entrega: mediana 10,2 $\rightarrow$ 14,0; PSI = 0,34;
- plazo prometido: 22,7 $\rightarrow$ 16,4 días; PSI = 0,96;
- KS: máxima distancia entre las dos distribuciones acumuladas (`scipy.stats.ks_2samp`).


Repaso: calibración y plan de monitoreo

De la S1

Un modelo calibrado dice 20 % y acierta 1 de cada 5. Se revisa con la curva de confiabilidad y el Brier score; se corrige con Platt o regresión isotónica. Con drift, la calibración se degrada aunque el AUC se mantenga.

Qué monitorear	Cómo	Si se dispara
Features	PSI, KS por variable	revisar el pipeline de datos
Predicciones	PSI de $\hat{y}$, nº de alertas	revisar el umbral
Calibración	curva y Brier con etiquetas nuevas	recalibrar (isotónica)
Desempeño	PR-AUC, Recall@k	reentrenar
Segmentos	tamaños, migración	reajustar o renombrar

El curso en una página



Idea clave: La regla que atraviesa el curso

Un resultado de ML vale lo que vale la evidencia que lo respalda: validación honesta, baseline, estabilidad y una decisión que cambie gracias a él.

Taller, examen y referencias

Taller / tarea: Checklist Módulo C

- features por cliente en SQL, hasta 2018-06-01;
- frecuencia casi constante: decida qué hacer;
- K-Means + otra familia; codo, silueta, DB y negocio;
- PCA + UMAP o t-SNE coloreados por segmento;
- ARI entre semillas o submuestras;
- perfiles, nombres y una acción por segmento.

Idea clave: Examen final

20 preguntas de opción múltiple (Interactiva): criterio, no memoria.

- Ester, M. et al. (1996). A density-based algorithm for discovering clusters (DBSCAN). *KDD*.
- Campello, R., Moulavi, D. y Sander, J. (2013). Density-based clustering based on hierarchical density estimates. *PAKDD*.
- Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2008). Isolation Forest. *ICDM*.
- Breunig, M. et al. (2000). LOF: identifying density-based local outliers. *SIGMOD*.
- Hubert, L. y Arabie, P. (1985). Comparing partitions. *J. Classification*.
- Ben-Hur, A., Elisseeff, A. y Guyon, I. (2002). A stability based method for discovering structure in clustered data. *PSB*.
- scikit-learn. Clustering; Novelty and outlier detection.

Gracias por su atención

¿Preguntas, comentarios o discusión?



Aprendizaje Automático
SI7009 · Universidad EAFIT

